전역·국소·하이브리드 잠재:
계층적 메시 GNN 위의 일대다 대체 모델
HI-MGN-V 와 cHI-MGNflow

AI-CAE4ALL 기술 리포트 `methods/MeshGraphNets_Variational`, `methods/HI_MGNFlow`

2026-10-12 (2026-09-18 판 전면 개정)

초록

같은 형상·같은 하중이 하나가 아닌 여러 응답을 낳는 문제가 있다. 원통 셸의 좌굴처럼, 입력에 나타나지 않는 미세한 초기 결함이 어느 분기로 갈지를 정하는 경우다. 결정론적 메시 GNN 은 이런 문제에서 분기들의 평균, 즉 어떤 실제 표본과도 닮지 않은 필드를 내놓는다. 본 리포트는 같은 계층적 메시 GNN(HI-MGN V-cycle) 위에서 **잠재 변수를 어디에 두는지만** 다른 두 생성 대체 모델을 코드 수준에서 기술하고 비교한다. **HI-MGN-V** 는 그래프당 하나인 96 차원 잠재를 AdaLN-Zero 로 V-cycle 의 모든 블록에 공간적으로 균일하게 주입한다 (전역). **cHI-MGNflow** 는 LDGN(Lino, Pfaff & Thuerey, ICLR 2025) 의 2 단계 설계를 따라 가장 coarse 한 레벨의 노드마다 4 채널 잠재 (256×4) 를 두고, 그 위에서 flow-matching prior 를 학습한다 (국소). 기본 prior 는 4-hop 수용영역의 국소 GNN 이다. 선택 옵션인 전역 토큰 (`prior_global token`) 은 *prior 내부에만* 그래프 단위 결합을 더하고, 잠재와 디코더는 국소로 남긴다 (하이브리드). 원통 셸 좌굴 데이터셋 (학습 150 형상 × 결함 64 표본, 입력은 결함 없는 공칭 형상) 에서 형상당 1000 표본으로 평가했다. cHI-MGNflow 는 평균을 맞추지만 (평균비 1.02) 퍼짐이 부족하다 (sd 비 0.66). HI-MGN-V 는 진폭이 작고 (평균비 0.83) 잘못된 분기에 질량을 둔다. test 의 W1/sd 는 0.69 대 1.38 이다. 진단 실험은 두 실패의 원인이 다름을 보인다. HI-MGN-V 는 인코더가 표본 간 변동의 절반 정도만 잠재에 담는다. 같은 디코더에서 z 를 직접 최적화하면 설명 비율이 0.85 까지 오른다. cHI-MGNflow 는 posterior 가 정확하지만 (sd 비 0.97), 국소 prior 가 노드 사이의 결합을 잃는다. 좌표별 분산은 맞지만 상위 주성분 방향의 분산은 0.4–0.5 배다. 이 결과가 전역 토큰을 추가한 동기이며, 토큰 실험은 아직 진행 중이다.

목차

1 서론 **2**

2 관련 연구 **5**

3 문제 설정 **5**

4 공유 백본: HI-MGN V-cycle 과 AdaLN-Zero **6**
4.1 메시지 패싱 블록과 계층 6
4.2 AdaLN-Zero(구현 그대로의 정의) 6

5 HI-MGN-V: 전역 잠재 **7**
5.1 구조 7
5.2 전역 설계의 성질 8

6 cHI-MGNflow: 국소 잠재 **8**
6.1 Stage 1: 계층 압축기 . . . 8
6.2 Stage 2: 잠재 flow-matching prior . . . 10
6.3 생성과 비용 . . . 10
6.4 학습 모드와 검증 지표 . . . 11

7 하이브리드: prior 안의 전역 토큰 **11**

8 세 설계의 비교 **12**

9 LDGN 과의 관계 **14**
9.1 원문의 사실 . . . 14
9.2 같은 점과 다른 점 . . . 14

10 실험: 원통 셸 좌굴 **15**
10.1 데이터셋과 해석 조건 . . . 15
10.2 모델 설정 . . . 18
10.3 평가 프로토콜 . . . 18
10.4 결과 . . . 18
10.5 HI-MGN-V 진단: 인코더가 병목이다 . . . 20
10.6 cHI-MGNflow 진단: prior 가 노드 간 결합을 잃는다 . . . 23
10.7 두 번째 데이터: SAOI 휨 . . . 24
10.8 진행 중: ex3 토큰 스윕 . . . 24

11 한계와 열린 문제 **25**

12 코드 위치 **25**

A 형상별 결과 **26**

B 2026-09-18 판 대비 정정 목록 **28**

1 서론

MeshGraphNets(MGN) 계열 모델은 encode–process–decode 구조로 메시 위의 물리량을 결정론적으로 예측한다 [1]. 이 구조는 입력이 응답을 유일하게 정하는 문제를 전제한다. 그러나 응답이 입력에 나타나지 않는 요인에 따라 갈리는 문제가 있다. 원통 셸의 축압축 좌굴이 대표적이다. 같은 공칭 형상, 같은 하중이라도 수십 μm 수준의 초기 결함이 좌굴 여부와 모드를 정한다. 이때 회귀 손실로 학습한 모델은 분기들의 조건부 평균 $\mathbb{E}[y \mid c]$ 로 수렴하고, 그 평균 필드는 어떤 실제 표본과도 닮지 않는다. 필요한 것은 조건부 분포 $p(y \mid c)$ 에서 표본을 뽑는 모델이다.

그림 1(a,b) 가 이 상황을 보여준다. 형상 g5($R = 158.6$, $t = 1.61$, $L = 206.2$, $\Delta = 1.02\,\mathrm{mm}$, $\lambda = 0.80$) 에서 64 개 결함 표본 중 16 개는 최대 변위가 4 mm 를 넘고 나머지는 1 mm 근처에 머문다. 모델이 보는 입력은 64 개 모두 같다.

이 문제에 대해 Lino, Pfaff & Thuerey [4] 는 DGN(필드 공간의 diffusion graph network) 과 LDGN(압축된 잠재 공간의 diffusion) 을 제안했다. LDGN 의 핵심은 두 단계다. 먼저 그래프 오토인코더로 필드를 coarse 노드별 잠재로 압축하고, 그다음 그 잠재 위에서만 생성 prior 를 학습한다. 본 리포트는 이 관점을 계층적 MGN 위로 옮기면서 하나의 설계 질문에 집중한다.

잠재 변수를 어디에 둘 것인가. 그래프 전체에 하나 (전역) 인가, coarse 메시 노드마다 (국소) 인가, 노드마다 두되 prior 가 전역적으로 결합하는 형태 (하이브리드) 인가.

분류 요약. 코드와 대조한 세 모델의 분류는 다음과 같다 (§8, 표 1).

- **HI-MGN-V — 전역.** 잠재 $z \in \mathbb{R}^{3\times 32}$ 가 그래프당 하나다. 레벨별 슬롯 z_l 이 그 레벨의 모든 노드에 같은 변조를 준다.
- **cHI-MGNflow, 기본 (`prior_global none`) — 국소.** 잠재 $z \in \mathbb{R}^{|V_L|\times C} = \mathbb{R}^{256\times 4}$ 이다. prior 는 G_L 위의 평탄한 GnBlock 4 개로, 수용영역이 4 hop 이다. G_L 의 지름은 18 hop 이다. 디코더도 국소적인 V-cycle 상승 경로다.
- **cHI-MGNflow, `prior_global token` — 하이브리드.** 2026-10-06(커밋 `5b61f5b`) 에 추가된 선택 옵션이다. 잠재와 디코더는 국소 그대로이고, *prior 의 velocity 네트워크 안에서만* 그래프당 전역 토큰 하나가 256 개 coarse 노드를 결합한다. 체크인된 ex3 baseline 설정은 이 키를 쓰지 않으므로 기본값 `none`(국소) 이다. 토큰은 `b300_sweep` 의 `tok*` 계열 arm 에서만 켜져 있다.

즉 "HI-MGN-V 는 전역, 기존 cHI-MGNflow 는 국소, 현재 cHI-MGNflow 는 하이브리드" 라는 구분은 맞다. 단, 하이브리드는 **prior** 에만 해당하고 옵션이다.

기여.

1. 같은 V-cycle 위에 전역/국소/하이브리드 잠재를 두는 두 모델을 구현과 일치하는 수준으로 정식화한다 (§4–7). 2026-09-18 판의 오기 (AdaLN-Zero 의 "항등 초기화", 추론 비용 "V-cycle 2 회", spread 지표의 정의, LDGN 에 대한 서술 등) 를 바로잡았다 (부록 B).
2. 원통 셸 좌굴 벤치마크와, 형상당 1000 표본·FEA 표본 노이즈 바닥을 쓰는 평가 프로토콜을 정리한다 (§10).
3. 두 모델의 실패를 분리하는 진단을 제시한다. posterior 와 prior 를 같은 고정 디코더로 비교하고, z 최적화와 shuffle/coherent 대조를 쓴다. HI-MGN-V 는 인코더 병목, cHI-MGNflow 는 prior 의 노드 간 결합 부족이 주원인이다.

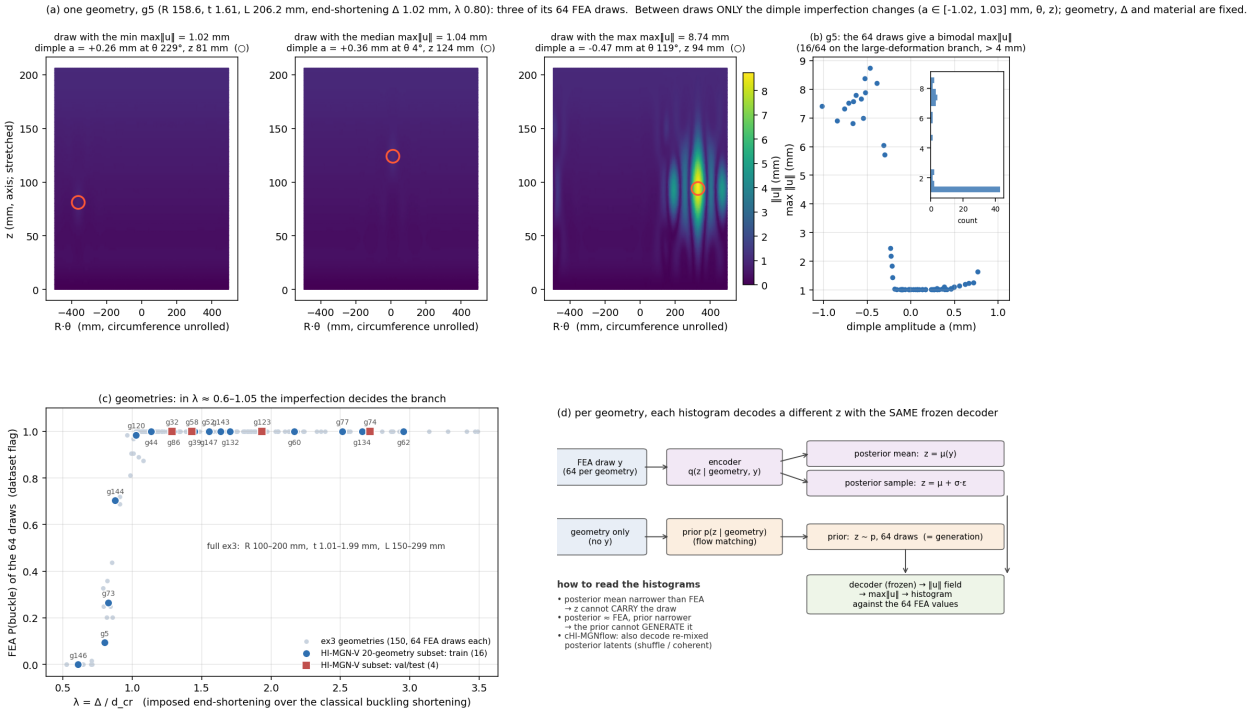


그림 1: 일대다 문제와 진단 절차. (a) 형상 g5 의 FEA 표본 세 개 (최소·중앙·최대; 최대 변위 1.02 / 1.04 / 8.74 mm). 세 표본의 모델 입력은 같다. (b) g5 의 64 개 표본에 대한 최대 $\|u\|$ 대 결함 진폭 a. 분포가 양봉이며, 16/64 가 4 mm 를 넘는다. (c) 학습 150 형상 전체의 FEA 좌굴 확률 $P(\text{buckle})$ 대 하중비 λ. 표시된 점은 HI-MGN-V 부분실험에 쓴 20 개 형상이다 (학습 16, 검증/시험 4: g32, g58, g123, g74). (d) 진단 절차 (§10.5, §10.6). posterior 평균, posterior 표본, prior 표본을 같은 고정 디코더로 디코딩해 FEA 히스토그램과 비교한다.

2 관련 연구

메시 GNN 과 멀티스케일. MGN [1] 은 메시 위의 메시지 패싱으로 시뮬레이션을 학습한다. 깊이가 고정된 메시지 패싱은 수용영역이 hop 수에 묶인다. 이를 넘기 위해 MS-MGN [2] 은 2-레벨 계층을, BSMS-GNN [3] 은 bi-stride 풀링 계층을 도입했다. 본 리포트의 백본 (HI-MGN) 은 FPS 시드와 BFS Voronoi 셀로 계층을 만들고, U-Net 형 V-cycle 로 레벨 사이를 오간다 (§4).

변분 오토인코더. VAE [6] 와 그래프 버전 VGAE [7] 는 posterior $q(z \mid y)$ 와 고정 prior $\mathcal{N}(0, I)$ 를 KL 로 맞춘다. InfoVAE [8] 는 KL 대신 집계 posterior 와 prior 사이의 MMD [9] 를 쓴다. HI-MGN-V 는 MMD 를 쓰고, 학습된 조건부 prior 를 따로 둔다.

DGN 과 LDGN. Lino, Pfaff & Thuerey [4] 는 메시 위의 조건부 분포 학습을 diffusion 으로 다룬다. 구체적인 사실은 §9 에서 정리한다. 요약하면 다음과 같다.

- DGN 은 필드 공간의 diffusion 이다.
- LDGN 은 그래프 오토인코더로 필드를 coarse 노드당 잠재로 압축하고, 그 위에서 멀티스케일 GNN denoiser 로 diffusion 을 한다.
- flow matching 변형 (FM-GNN/LFM-GNN) 은 부록 D.7 에서 실험된다.
- 기준선 VGAE(학습된 prior 없음) 는 EllipseFlow 에서 mode collapse 한다.

후속 SAR [5] 는 Transolver 계열 전역 어텐션과 AdaLN-Zero 를 쓰는 순수 flow matching 모델이다.

Flow matching. Flow matching [10] 과 rectified flow [11] 는 노이즈와 데이터 사이의 직선 경로 위 속도장을 회귀한다. SD3 [12] 는 시간 t 를 logit-normal 로 뽑는 것이 유리하다고 보고했다. cHI-MGNflow 는 두 방식을 모두 옵션으로 가진다.

조건화와 전역 노드. FiLM [13] 은 조건으로 특징의 scale/shift 를 변조한다. AdaLN-Zero [14] 는 LayerNorm 뒤에 이를 적용하고, 잔차 gate 를 0 으로 초기화한다. 본 구현의 "AdaLN-Zero" 는 LayerNorm 이 없고 gate 가 1 로 초기화되므로 FiLM+gate 에 가깝다 (§4.2). 그래프 전역 정보를 한 노드로 모으는 virtual/master node [15] 와 GN 프레임워크의 전역 속성 u [16] 가 §7 의 전역 토큰의 선례다.

확률 예측 평가. CRPS [17] 는 표본 앙상블을 평가하는 proper score 다. 앙상블 크기의 편향을 없앤 fair CRPS [18] 를 쓴다. 1-Wasserstein 거리와 KS 통계량은 분포 형태를 직접 비교한다.

3 문제 설정

메시 $G = (V, E)$ 위의 입력 c 와 출력 $y \in \mathbb{R}^{|V| \times 3}$ 를 생각한다. 원통 셀 좌굴 (§10) 에서 각 항목은 다음과 같다.

- c 는 결함 없는 공칭 원통의 노드 좌표, 노드별 조건 행 (두께 t, 강제 변위 Δ), 노드 타입이다.
- y 는 하중 종료 시점의 노드 변위다.
- 솔버가 실제로 푼 초기 형상은 공칭 형상에 국소 딤플 결함 $\xi = (a, z_c, \theta_c)$(진폭, 축방향 위치, 원주각) 를 더한 것이다.

- ξ 는 모델 입력에 없다. 데이터셋에는 진단용으로만 저장된다.

따라서

$$y = S(c, \xi), \qquad \xi \sim p(\xi), \qquad p(y \mid c) = \int \delta\big(y - S(c,\xi)\big)\, p(\xi)\, d\xi \tag{1}$$

이다. 학습 데이터는 형상마다 64 개의 ξ 표본에서 얻은 (c, y) 쌍이다. 모델은 같은 c 에 대해 서로 다른 64 개의 y 를 본다. 목표는 처음 보는 c 에 대해 $p(y \mid c)$ 의 표본을 생성하는 것이다. 평가는 필드 전체가 아니라 공학 통계량 (최대 변위, 좌굴 확률) 의 형상별 분포로 한다 (§10.3).

4 공유 백본: HI-MGN V-cycle 과 AdaLN-Zero

4.1 메시지 패싱 블록과 계층

기본 단위는 잔차 MGN 블록 (GnBlock) 이다.

$$e'_{ij} = e_{ij} + \phi^e\big([h_i, h_j, e_{ij}]\big), \qquad h'_i = h_i + \phi^v\Big(\big[h_i,\ \textstyle\sum_j e'_{ij}\big]\Big). \tag{2}$$

아래에서 블록의 잔차 갱신량을 $\Delta_B(h) := B(h) - h$ 로 쓴다.

계층 $G_0 \supset G_1 \supset \cdots \supset G_L$ 은 `voronoi_seedmean` 으로 만든다. 각 레벨에서 FPS 로 시드 N_l 개를 고르고, fine 그래프 위에서 다중 출발점 BFS 로 Voronoi 셀 $\mathcal{C}_k$ 를 나눈다. 셀 평균으로 풀링한다.

$$h_k^{l+1} = \frac{1}{|\mathcal{C}_k|} \sum_{i \in \mathcal{C}_k} h_i^l. \tag{3}$$

coarse 간선은 인접한 셀 사이에 놓는다. 간선 특징은 8 차원 기하 속성에서 다시 인코딩한다. ex3 설정은 $L = 2$, $N_1 = 4096$, $N_2 = 256$ 이다. fine 메시는 24,852–87,398 노드 (중앙값 45,623) 다. 따라서 coarsest 노드 하나가 평균 약 180 개 fine 노드를 대표한다. G_2 의 지름은 18 hop 이고, 평균 최단경로는 9.2 hop 이다.

상승 경로의 unpool 은 coarse→fine 이분 그래프 위의 메시지 패싱이다 (`UnpoolBlock`). s_i^l 는 하강 경로에서 저장한 skip 특징이다.

$$m_{k\to i} = \phi^u\big([h_k^{l+1},\ s_i^l,\ p_i - p_k]\big), \qquad h_i^l = \psi^u\Big(\big[s_i^l,\ \textstyle\sum_{k\to i} m_{k\to i}\big]\Big). \tag{4}$$

레벨별 블록 수는 `mp_per_level 2,3,5,3,2` 이다. 하강 경로에서 G_0 에 2 개, G_1 에 3 개, G_2(coarsest) 에 5 개, 상승 경로에서 G_1 에 3 개, G_0 에 2 개로 모두 15 개다.

학습 때는 샘플마다 서로 다른 시드로 만든 두 분할 중 하나를 쓴다 (`hierarchy_variants 2`). 추론 때는 `hierarchy_seed 42` 로 만든 단일 분할을 쓰는데, 이 분할은 학습 캐시에 없다 (§11).

4.2 AdaLN-Zero(구현 그대로의 정의)

두 모델은 조건 벡터 ζ(HI-MGN-V 에서는 잠재 슬롯 z_l, cHI-MGNflow prior 에서는 시간 임베딩 $\tau(t)$) 로 GnBlock 을 변조한다 (`blocks.py::AdaLNZero`). 변조 파라미터와 갱신은 다음과 같다.

$$(\beta,\ \gamma,\ g) = W\,\mathrm{SiLU}(\zeta) + b, \qquad W = 0,\ b = (0,\,0,\,1) \text{ 로 초기화}, \tag{5}$$

$$\tilde{h} = h \odot (1 + \gamma) + \beta, \qquad h' = h + g \odot \Delta_B(\tilde{h}) = h + g \odot \big(B(\tilde{h}) - \tilde{h}\big). \tag{6}$$

초기화 시점에는 $\beta = \gamma = 0$, $g = 1$ 이므로 $h' = h + \Delta_B(h) = B(h)$ 다. 즉 **변조 블록은 초기에 조건이 없는 원래 블록과 정확히 같다**. 항등함수가 아니다. 조건이 처음에는 아무 효과가 없다가,

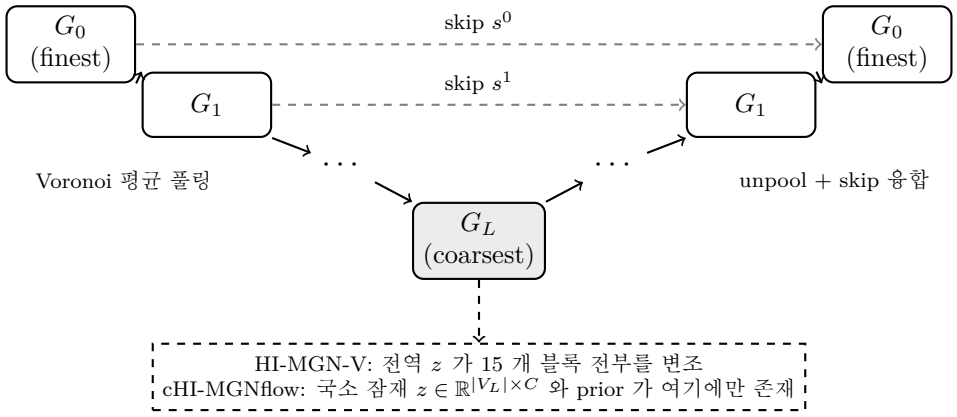


그림 2: 공유 백본인 HI-MGN V-cycle. 블록 수는 하강 2/3, coarsest 5, 상승 3/2 다. 두 모델은 같은 V-cycle 을 쓰고, 잠재를 넣는 위치만 다르다.

학습되며 효과가 커진다. DiT 의 AdaLN-Zero [14] 와 다른 점은 두 가지다. LayerNorm 이 없고, gate 가 0 이 아닌 1 로 초기화된다. 따라서 이 연산은 "gate 가 붙은 FiLM" [13] 에 더 가깝다. 노드 특징만 변조하고, 간선 특징은 변조하지 않는다.

이 밖에도 출력 헤드는 거의 0 으로 초기화한다. HI-MGN-V 디코더의 마지막 층과 cHI-MGNflow 의 `out_head` 는 가중치에 0.01 을 곱하고, 토큰의 `g_out` 은 0 으로 둔다. 이 초기화들은 전역 kaiming 초기화 뒤에 `reset_zero_init_heads` 로 다시 적용해야 유지된다.

5 HI-MGN-V: 전역 잠재

5.1 구조

Posterior 인코더. $q_\phi(z \mid y, c)$ 는 fine 메시 G_0 위에서 동작한다 (`GNNVariationalEncoder`, `graph_aware`).

$$h_i = \mathrm{GnBlock}^3\Big(\mathrm{Fuse}\big[\mathrm{Enc}_y(y_i),\ \mathrm{Enc}_x(x_i)\big]\Big), \tag{7}$$

$$a = \sum_i \mathrm{softmax}_i\big(w^\top h_i\big)\, h_i, \tag{8}$$

$$(\mu,\ \log\sigma^2) = \big(W_\mu a,\ W_\sigma a\big) \in \mathbb{R}^{(L+1)\times 32}, \qquad \log\sigma^2 \geq 2\log 0.05. \tag{9}$$

`vae_mp_layers 3` 이므로 풀링 전 수용영역은 fine 메시에서 3 hop 뿐이다. 그 위에 어텐션 풀링 헤드가 하나 있다. 이 병목이 §10.5 의 핵심 진단이다.

디코더. 그림 2 의 HI-MGN V-cycle 전체 (15 블록) 를 쓴다. 모든 processor GnBlock 을 AdaLN-Zero 로 변조한다. 레벨 $l < L$ 의 하강·상승 블록은 슬롯 z_l 을, coarsest 블록은 z_L 을 받는다. z 는 그래프당 하나이므로 같은 레벨의 모든 노드가 **같은** (β, γ, g) 를 받는다. 공간적 차이는 메시 특징과 메시지 패싱을 통해서만 생긴다.

손실. KL 항은 없다.

$$\mathcal{L}_\mathrm{V} = \alpha\,\|\hat{y} - y\|^2 + \lambda\,\mathrm{MMD}\big(q(z), \mathcal{N}(0, I)\big) + \beta_\mathrm{aux}\big(\mathrm{PV}(\hat{y}_z) - \mathrm{PV}(y_z)\big)^2 + w_p\,\mathcal{L}_\mathrm{FM}, \tag{10}$$

설정값은 $\alpha = 1000$, $\lambda = 1$, $\beta_\mathrm{aux} = 10$, $w_p = 1$ 이다.

- MMD 는 슬롯마다 따로 계산해 평균한다. RBF 커널의 기준 대역폭은 배치 내 교차 거리의 중앙값이고, 배율 $\{0.25, 0.5, 1, 2, 4\}$ 를 쓴다. 배치 안의 표본만으로 계산하므로 GPU 당 배치가 2 이하이면 사실상 상수 (1.2373) 가 되어 아무 역할을 하지 않는다 (§11).
- PV 는 디코딩된 3 번째 채널 (u_z) 의 그래프별 peak-to-valley 다.

조건부 prior $p_\psi(z \mid c)$. `ConditionalFMPrior` 다.

- 조건 trunk 는 fine 메시 G_0 위에서 동작한다. 노드·간선 MLP 와 GnBlock 3 개 (은닉 128) 를 거친 뒤 어텐션 풀링으로 $c_g \in \mathbb{R}^{128}$ 를 만든다.
- 속도장은 $[z_t\ (96) \mid \tau(t)\ (32) \mid c_g\ (128)]$ 을 입력으로 받는 MLP(은닉 128) 다.
- flow matching 식은 cHI-MGNflow 와 같다 (식 18, $\sigma_{\min} = 10^{-4}$).
- 목표 z_1 은 posterior 에서 새로 뽑아 detach 한다 (`prior_grad_to_encoder 0`).

학습 일정.

1. 80 epoch 동안 VAE 와 prior 를 함께 학습한다.
2. 그 시점에 오토인코더를 동결하고 상태를 `.joint.pth` 로 저장한다.
3. posterior 표본 통계로 z 표준화 버퍼 (`z_shift`, `z_scale`) 를 만든다.
4. prior 전용 optimizer 로 40 epoch 을 더 학습한다.

추론. $z_0 \sim \mathcal{N}(0, I)$ 에서 출발해 Heun 30 스텝으로 적분한다. 결과를 표준화 이전 척도로 되돌린 뒤 V-cycle 을 한 번 디코딩한다. 자기회귀 롤아웃에서는 z 를 궤적 전체에 고정한다. ex3 는 정적 문제 ($T = 1$) 라 이 구분이 영향을 주지 않는다.

5.2 전역 설계의 성질

전역 잠재의 장점은 두 가지다. 96 개 숫자로 "어느 분기인가" 를 한 번에 정할 수 있고, prior 가 저차원 MLP 라 싸다. 대가는 디코더에 있다. 국소 딤플이 만든 국소 좌굴 패턴을 공간적으로 균일한 변조만으로 "그려야" 한다. 인코더도 y 의 국소적 차이를 3-hop 특징과 풀링 하나로 96 개 숫자에 담아야 한다. §10.5 의 실험은 이 두 번째 병목이 주원인임을 보인다.

6 cHI-MGNflow: 국소 잠재

cHI-MGNflow 는 LDGN 의 2 단계 원칙을 HI-MGN V-cycle 위에 구현한다. 1 단계는 거의 무손실인 계층 압축기이고, 2 단계는 압축된 coarsest 잠재 위의 flow-matching prior 다. 데이터 흐름은 그림 3 와 같다.

6.1 Stage 1: 계층 압축기

입력 조립. `_build_work_graph` 는 노드 입력을 $x' = [x_{\text{state}},\ y,\ x_{\text{cond}},\ \ldots]$ 로 만든다. y-blind pass 에서는 y 자리에 0 을 넣는다.

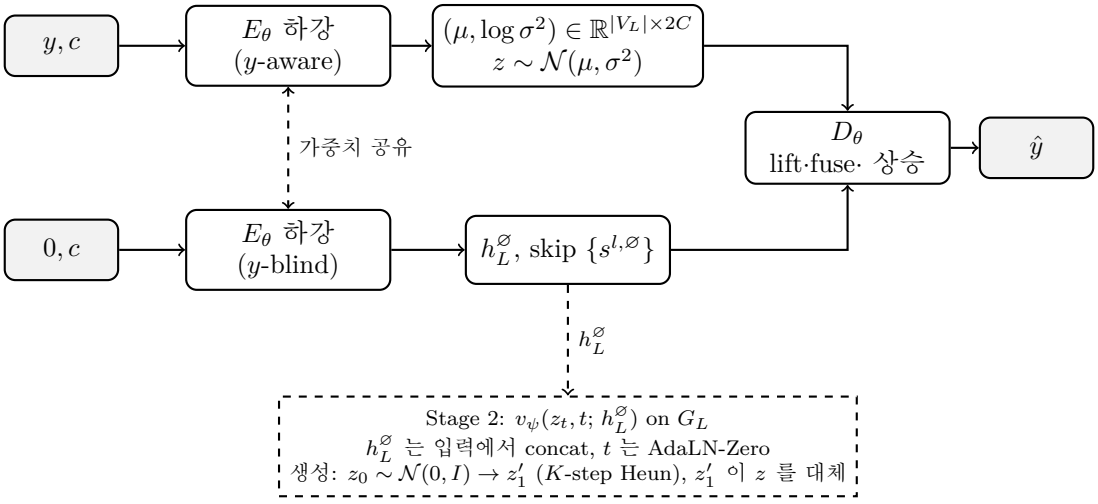


그림 3: cHI-MGNflow 의 데이터 흐름. 같은 가중치의 하강 인코더 E_θ 를 y 를 넣은 pass 와 $y = 0$ 인 pass 로 두 번 호출한다. 잠재는 y-aware pass 에서 나온다. 디코더 skip 과 prior 조건은 y-blind pass 에서만 나온다.

인코더. `HierarchyEncoder` 는 V-cycle 의 하강 경로다 (G_0 에 2, G_1 에 3, G_2 에 5 블록, 모두 10 블록). 한 스텝에 두 번 실행된다.

$$(\mu,\ \log\sigma^2) = \mathrm{LatentHead}\big(h_L^y\big) \in \mathbb{R}^{|V_L|\times 2C}, \qquad \log\sigma^2 \in [-10, 10], \qquad z = \mu + \sigma \odot \varepsilon, \tag{11}$$

$$\big(h_L^\varnothing,\ \{s^{l,\varnothing}\}_{l<L}\big) = E_\theta(0, c). \tag{12}$$

첫 줄은 y-aware pass 이고, 둘째 줄은 y-blind pass 다. $C = \texttt{latent_ch} = 4$ 다. 잠재 크기는 $256 \times 4 = 1024$ 이고, 출력 필드 (중앙값 45,623 노드 $\times$ 3) 에 비하면 약 134 배 압축이다.

디코더. `MultiscaleDecoder` 다.

$$h = W_{\text{fuse}}\big[h_L^\varnothing,\ W_{\text{lift}}\, z\big] \qquad (W_{\text{lift}} : \mathbb{R}^C \to \mathbb{R}^D \text{ 노드별 채널 변환}), \tag{13}$$

$$h \leftarrow \mathrm{GnBlock}^5(h) \qquad (\texttt{post_z_blocks}, \text{coarsest}), \tag{14}$$

$$h \leftarrow \mathrm{Post}_l\Big(W_{\text{skip}}^l\big[s^{l,\varnothing},\ \mathrm{Unpool}(h, s^{l,\varnothing})\big]\Big), \qquad l = L-1, \ldots, 0, \tag{15}$$

$$\hat{y} = \mathrm{Dec}(h). \tag{16}$$

상승 블록은 Post_1 이 3 개, Post_0 이 2 개로, coarsest 5 개와 합쳐 10 블록이다. 디코더 블록은 AdaLN 없이 평범한 GnBlock 이다. 마지막 층의 가중치에는 0.01 을 곱해 초기화한다.

z 의 lift 는 *채널* 변환 ($C \to D$) 이지 노드 수를 늘리는 연산이 아니다. 노드 수는 처음부터 $|V_L|$ 이다. skip 이 y-blind 이므로 y 의 정보가 디코더에 닿는 길은 z 하나뿐이다. 이 구조가 "디코더가 z 를 우회해 skip 에서 정답을 읽는" 붕괴를 막는다. LDGN 의 VGAE 기준선은 skip 이 없는 구조라 같은 실패는 아니다. 다만 "디코더가 조건에 지나치게 의존한다" 는 저자들의 설명과 같은 방향의 방지책이다.

손실.

$$\mathcal{L}_{\text{AE}} = \big\|w \odot (\hat{y} - y)\big\|^2 + \beta_{\text{KL}}\, \overline{\mathrm{KL}}\big(\mathcal{N}(\mu, \sigma^2)\,\|\,\mathcal{N}(0, I)\big), \qquad \beta_{\text{KL}} = 10^{-6}. \tag{17}$$

$\overline{\mathrm{KL}}$ 은 원소당 평균이다. LDGN 과 달리 잠재에 BatchNorm 같은 정규화는 없다.

6.2 Stage 2: 잠재 flow-matching prior

1 단계 오토인코더를 동결한 뒤, $q(z \mid y, c)$ 의 표본 z_1(`no_grad`) 과 $z_0 \sim \mathcal{N}(0, I)$ 를 잇는 경로에서 속도장을 회귀한다.

$$s = 1 - \sigma_{\min}, \qquad z_t = (1 - s\,t)\,z_0 + t\,z_1, \qquad u_t = z_1 - s\,z_0,$$
$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}_{t,z_0,z_1}\Big[w(t)\,\big\|v_\psi(z_t, t;\, h_L^{\varnothing}) - u_t\big\|^2\Big]. \tag{18}$$

설정은 다음과 같다.

- $\sigma_{\min} = 10^{-4}$ 이다.
- t 는 `uniform`(기본) 이나 `logitnormal` 로 뽑는다.
- $w(t)$ 는 1(기본) 이나 $(1 - s\,t)^2$ 이다. 후자는 데이터 예측 오차와 같은 가중이다 (`x0`).
- `flow_det_prob` p 를 주면 확률 p 로 $t = 0$ 을 고정해 학습한다.

속도장 네트워크 (`LatentFlowPrior`).

$$u^{(0)} = W_{\mathrm{in}}\big[z_t,\ h_L^{\varnothing}\big], \qquad u^{(j)} = \mathrm{AdaLN}_j\big(\mathrm{GnBlock}_j;\ \tau(t)\big)\big(u^{(j-1)}\big), \qquad v_\psi = W_{\mathrm{out}}\,u^{(B)}. \tag{19}$$

- 전체가 G_L(256 노드) 위에서 동작하며, 추가 풀링 없이 평탄하다 (`prior_blocks` $B = 4$).
- 그래프 조건 $h_L^{\varnothing}$ 은 **입력 projection 에서 concat** 으로만 들어간다.
- AdaLN-Zero 는 **시간 임베딩** $\tau(t)$ **만** 받는다 (주파수 16 개 $\to$ 32 차원).
- W_{out} 의 가중치에는 0.01 을 곱해 초기화한다.

블록 B 개의 수용영역은 B hop 이다. G_L 의 지름이 18 hop 이므로 기본 prior 는 **국소적**이다. 한 노드의 속도가 멀리 떨어진 노드의 z_t 를 볼 수 없다.

6.3 생성과 비용

`generate` 의 순서는 다음과 같다.

1. y-blind 하강 1 회 (10 블록) 로 $h_L^{\varnothing}$ 와 skip 을 만든다.
2. $z_0 \sim \mathcal{N}(0, I) \in \mathbb{R}^{|V_L| \times C}$ 에서 출발해 Heun K 스텝으로 적분한다. prior 평가는 $2K$ 회이고, 각각 G_L 위의 B 블록이다.
3. 디코더 1 회 (coarsest 5 + 상승 5 블록) 로 필드를 만든다.

즉 비용은 "V-cycle 2 회" 가 아니라 **하강 1 회 + 상승 1 회**, 곧 V-cycle 1 회분이다. 여기에 256 노드 위의 작은 반복이 붙는다 (그림 5). fine 레벨 (G_0) 블록 수는 cHI-MGNflow 가 4 개 (하강 2, 상승 2) 다. HI-MGN-V 는 7 개 (V-cycle 4 + 조건 trunk 3) 다. 학습 한 스텝은 하강 2 회 (y-aware, y-blind) 와 상승 1 회다.

읽기 모드 (`predict`).

- `sample`(기본): 위 절차 그대로다.
- `mean`: $t = 0$ 에서 한 번 평가해 $\hat{z} = z_0 + v_\psi(z_0, 0) \approx \mathbb{E}[z_1 \mid c] + \sigma_{\min} z_0$ 를 디코딩한다. 이것은 **잠재 평균**이다. 디코더가 비선형이므로 $D(\mathbb{E}[z]) \neq \mathbb{E}[y \mid c]$ 이고, 분기가 갈리는 문제에서는 어느 분기도 아닌 필드가 나올 수 있다.

- `ensemble_mean`: 표본을 디코딩한 뒤 필드 *공간에서* 평균한다. `generate` 는 이 모드를 직접 처리하지 않고 오류를 낸다. 호출자가 표본을 모아 평균해야 한다.

자기회귀 롤아웃은 매 스텝 새 z_0 를 뽑는다. 정적 문제인 ex3 에는 해당하지 않는다.

6.4 학습 모드와 검증 지표

모드.

- `train_ae`: 1 단계만 학습한다.
- `train_prior`: 저장된 AE(EMA 가중치 우선) 를 불러와 동결하고 prior 만 학습한다.
- `train`: `ae_epochs`(ex3: 60) 동안 1 단계를 학습하고, 이어서 `training_epochs`(ex3: 120) 동안 prior 를 학습한다. 이 모드에서는 **마지막 epoch 의** AE 가 메모리에서 동결되며 (best 가 아님), 두 단계가 같은 `modelpath` 에 덮어쓴다.

`training_seed` 는 어디에서도 읽지 않는다. 같은 설정을 반복하면 그것이 곧 노이즈 바닥 arm 이다.

검증 지표 (`val_num_samples` 8, `val_flow_steps` 30).

- **crps**: 노드·채널별 fair CRPS 의 평균.
- **mean**: 표본 0 번 하나의 MSE. 재구성 오차가 *아니다*.
- **det**: `predict='mean'` 읽기의 MSE.
- **spread**: 그래프마다 표본 간 표준편차의 노드 평균을 그 *정답 필드 하나의 공간 표준편차*로 나눈 값의 평균. 분모는 참 조건부 분포의 표준편차가 아니므로 이 값의 목표는 1 이 아니다. 같은 실험 안의 상대 비교에만 쓴다.

체크포인트는 `best_by crps` 로 고른다.

7 하이브리드: prior 안의 전역 토큰

동기. 정확한 flow-matching 속도 $\mathbb{E}[u_t \mid z_t]$ 는 노드 i 에서도 z_t *전체*에 의존한다. 한 표본이 어느 좌굴 분기로 가는지는 잠재 전체의 성질이기 때문이다. B-hop 국소 trunk 는 노드별 주변분포는 맞출 수 있지만, 노드들이 함께 움직이는 큰 규모의 모드를 퍼뜨리지 못한다. ex3 에서 블록을 4 개에서 16 개로 늘려도 퍼짐이 거의 넓어지지 않았다 (§10.6).

정의 (`prior_global token`, `LatentFlowPrior._token_trunk`). 그래프 b 마다 토큰 $g_b \in \mathbb{R}^D$ 를 0 에서 시작한다. 각 블록 j *앞에서* 다음을 수행한다.

$$\bar{u}_b = \frac{1}{|V_L^{(b)}|} \sum_{i \in V_L^{(b)}} u_i, \tag{20}$$

$$g_b \leftarrow g_b + \phi_j\big([g_b,\ \bar{u}_b,\ \tau(t)]\big), \tag{21}$$

$$u_i \leftarrow u_i + W_j^g\, g_{b(i)}, \tag{22}$$

$$u \leftarrow \mathrm{AdaLN}_j\big(\mathrm{GnBlock}_j; \tau(t)\big)(u). \tag{23}$$

ϕ_j 는 MLP$(2D+32 \to D)$ 이고, W_j^g 는 0 으로 초기화한다. g 가 0 에서 시작하고 W^g 가 0 이므로, **초기화 시점의 토큰 prior 는 국소 prior 와 정확히 같다.** 토큰은 학습이 필요하다고 판단할 때만 쓰인다.

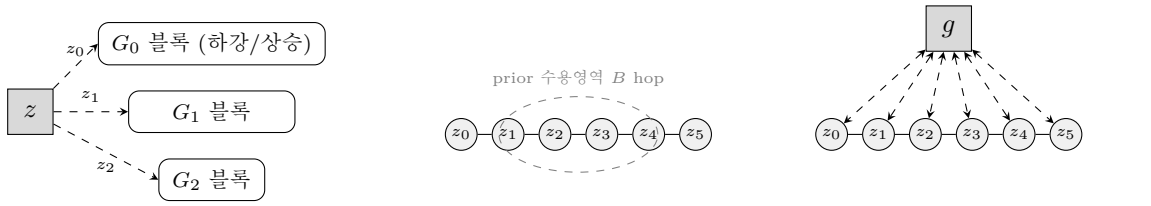
범위. 토큰은 prior 속도장 안에만 있다. 잠재는 여전히 $\mathbb{R}^{|V_L|\times C}$ 의 국소 잠재이고, 디코더는 바뀌지 않는다. 따라서 하이브리드는 "국소 잠재 + 전역적으로 결합된 prior" 다. HI-MGN-V 처럼 잠재 자체가 전역인 것과는 다르다. 비용은 블록마다 MLP 한 번과 scatter-mean 한 번이다. 두 경우 비용 구조 (그림 5) 는 사실상 같다.

현황.

- 기본값은 `none` 이다.
- ex3 B300 스윕 (`configs/HI_MGNFlow/probabilistic/ex3/b300_sweep/`) 은 8 arm 으로 구성된다.
  - `ctrl`: 토큰 없음.
  - `tok`: 토큰.
  - `tok_seed`: `tok` 반복 (노이즈 바닥).
  - `tok_b8`: 배치 8.
  - `tok_w256`: 폭 256.
  - `tok_long`: AE 120 / prior 240 epoch.
  - `tok_kl`: $\beta_{\mathrm{KL}} = 10^{-4}$.
  - `tok_g64`: 계층 4096/64, $C = 16$.

  이 스윕의 결과는 아직 없다.
- SAOI 스윕에서 `tok` 은 학습 부품은 잘 맞추지만, 처음 보는 부품에서는 폭과 모양이 모두 어긋났다 (§10.7).

8 세 설계의 비교



(a) HI-MGN-V: 전역 $z \in \mathbb{R}^{3\times 32}$, 그래프당 하나

(b) cHI-MGNflow 기본: 국소 $z \in \mathbb{R}^{256\times 4}$, prior = 국소 GNN

(c) `prior_global token`: 하이브리드 잠재·디코더 국소, 결합은 prior 안에서만

그림 4: 잠재의 위치. (a) 그래프당 하나인 z 가 V-cycle 모든 레벨을 변조한다. (b) coarsest 노드마다 잠재가 있고, prior 는 이웃끼리만 정보를 교환한다. (c) (b) 와 같은 잠재에 대해, prior 속도장 안의 전역 토큰 g 가 모든 노드를 결합한다.

	HI-MGN-V	cHI-MGNflow (기본)	cHI-MGNflow + token	cHI v1 (폐기)
잠재 위치	그래프당 3×32	coarsest 노드당 256×4	동일	없음 (필드 공간)
잠재 주입	AdaLN-Zero, 15 블록 전부, 공간 균일	coarsest 에서 concat 후 상승	동일	—
posterior	fine 메시 3 블록 + 어텐션 풀링	V-cycle 하강 (y-aware)	동일	—
정규화	MMD($\lambda = 1$), KL 없음	KL 10^{-6}	동일	—
prior	MLP + fine 메시 조건 trunk	G_L 위 국소 GNN, B hop	+ 전역 토큰	필드 FM, V-cycle 전체
학습	joint 80 + prior 40 epoch	AE 60 → 동결 → prior 120	동일	1 단계
생성 비용	trunk + $2K$ MLP + V-cycle 1 회	하강 + $2K \times B$ 블록 (G_L) + 상승	동일 (+MLP)	$2K$ V-cycle
G_0 블록 수	7	4	4	$4 \times 2K$

표 1: 세 설계 (와 이전 v1) 의 비교. “동일” 은 바로 왼쪽 열과 같다는 뜻이다.

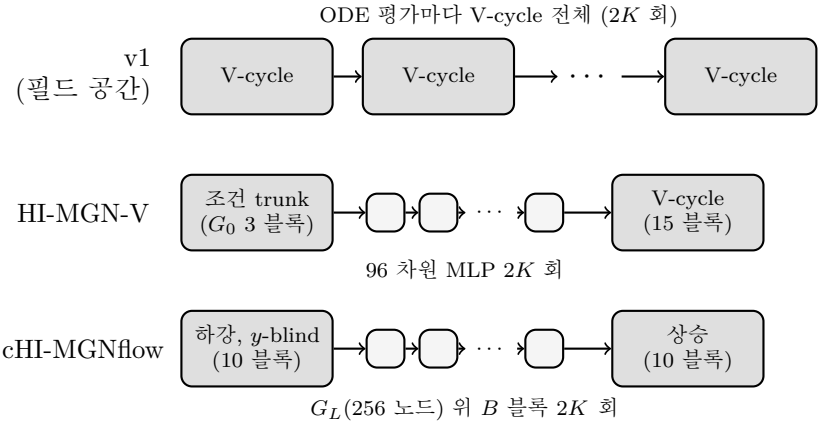


그림 5: 표본 하나를 생성하는 비용. 회색 큰 상자는 fine 메시를 지나는 연산이고, 흰 작은 상자는 K-step Heun 의 반복 (평가 $2K$ 회) 이다. 두 현재 모델 모두 fine 메시 연산은 V-cycle 1 회분이고, 반복은 작은 공간에서만 일어난다.

9 LDGN 과의 관계

참고 논문은 Lino, Pfaff & Thuerey, *Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks*, ICLR 2025 (OpenReview `uKZdlihDDn`, arXiv:2504.02843) 이다. 2026-09-18 판의 몇몇 서술은 원문과 맞지 않았다. 아래가 바로잡은 내용이다.

9.1 원문의 사실

- **압축.** LDGN 은 그래프 오토인코더로 필드를 Guillard 코스닝 계층의 coarse 노드별 잠재로 압축한다. coarse 노드당 채널 수는 $F_L = 1$ 이다. 노드 수 압축은 1D 에서 4 배, 2D 에서 16 배이고, EllipseFlow 에서는 3 개 필드가 채널 1 개로 줄어든다. KL 가중은 10^{-6} 이다. 오토인코더를 먼저 학습해 동결한 뒤 denoiser 를 학습하는 2 단계다.
- **조건 인코더.** 조건 인코더가 레벨별 조건 특징을 만들어 노드 인코더와 디코더의 모든 레벨에 넣는다. denoiser 는 그중 coarsest 조건만 입력에 더해 받는다. cHI-MGNflow 가 $h_L^{\varnothing}$ 을 `in_proj` 에서 concat 하는 것과 같은 역할이다.
- **denoiser.** 잠재 위에서도 멀티스케일 U-Net 이다. 구성은 "2+2", "2+3", "2+4" 등이다. 원문의 "단일 스케일 실패" ablation(Table 11, Fig. 15, App. D.2) 은 *필드 공간 DGN* 에 대한 것이다. 약 70 노드에서는 성능이 나빠지고, 2.3k/6.8k 노드에서는 아예 학습이 불가능했다. LDGN 의 잠재 denoiser 를 단일 스케일로 한 실험은 아니다.
- **시간 주입.** 확산 스텝 임베딩을 매 층에 더한다. AdaLN 은 쓰지 않는다.
- **Flow matching.** 초록과 App. D.7 에서 FM-GNN/LFM-GNN 을 실험한다. 스텝 10 이하에서는 FM 이, 약 20 이상에서는 diffusion 이 낫다. 공개 코드는 $\sigma_{\min} = 10^{-3}$ 에 Euler 적분이다. 본문에 FM 수식은 없다. 2026-09-18 판은 "FM 은 실험이 없다" 고 썼는데, 틀린 서술이다.
- **VGAE 기준선.** 학습된 prior 가 없고, 잠재가 더 깊으며 skip 이 없다. Ellipse 에서는 KL 10^{-3}, $F_L = 4$ 로 동작한다 (B.5 본문은 1 로 적음). EllipseFlow 에서는 KL 10^{-8}, $F_L = 32$ 로 mode collapse 한다. 저자들은 이를 "디코더가 입력 조건에 지나치게 의존하고 잠재가 덜 압축되었기 때문" 으로 설명한다. 2026-09-18 판의 "더 무거운 KL, 더 coarse 한 잠재가 원인" 이라는 요약은 반대 방향의 오독이다.
- **결과.**
  - EllipseFlow W_2^{graph} 는 LDGN 3.07, DGN 4.72, VGAE 6.10 이다. R^2 는 DGN 이 가장 높다.
  - Wing 50 스텝 생성 시간은 LDGN 0.20 s, DGN 0.59 s 다.
  - 지표는 W_2^{node}, W_2^{graph}, R^2 이다.
  - 한계로 시간 상관이 없다는 점을 든다.
- **후속 (SAR, arXiv:2604.11403).** $K = 3$ Guillard 스케일, Transolver+AdaLN-Zero, 전역 어텐션, 순수 FM 구성이다. EllipseFlow W_2 는 SAR 1.64 대 LDGN 3.07 이다. 전역 결합이 이득이라는 점에서 §7 과 같은 방향이다.

9.2 같은 점과 다른 점

항목	LDGN	cHI-MGNflow
2 단계 설계	AE 학습 → 동결 → 잠재 생성 모델	같음 (`train` 또는 `train_ae`→`train_prior`)
잠재	Guillard coarse 노드당 $F_L = 1$, KL 10^{-6}	Voronoi coarsest 노드당 $C = 4$, KL 10^{-6}, 잠재 정규화 없음
조건 경로	별도 조건 인코더, 레벨별 조건을 AE 전 레벨에 넣음	같은 하강 인코더의 y-blind pass; skip 과 $h_L^{\varnothing}$
denoiser 조건	coarsest 조건을 입력에 더함	$h_L^{\varnothing}$ 을 입력에 concat
denoiser 구조	잠재 위 멀티스케일 U-Net	G_L 위 평탄 GnBlock B 개 (국소) 또는 + 전역 토큰
시간 주입	매 층에 임베딩을 더함	AdaLN-Zero(LN 없음, gate 1 초기화)
생성 모델	DDPM 형 diffusion(주), FM 은 App. D.7	flow matching 만, Heun 적분
coarsening	Guillard, 레벨당 1D ∼2 배 / 2D ∼4 배	FPS + BFS Voronoi, ∼45k→4096→256

표 2: LDGN 과 cHI-MGNflow. 가장 큰 차이는 denoiser 구조다. LDGN 은 잠재 위에서도 멀티스케일로 넓은 수용영역을 갖는다. cHI-MGNflow 의 기본 prior 는 국소적이다. 전역 토큰은 이 차이를 메우는 가장 싼 방법이다.

10 실험: 원통 셸 좌굴

10.1 데이터셋과 해석 조건

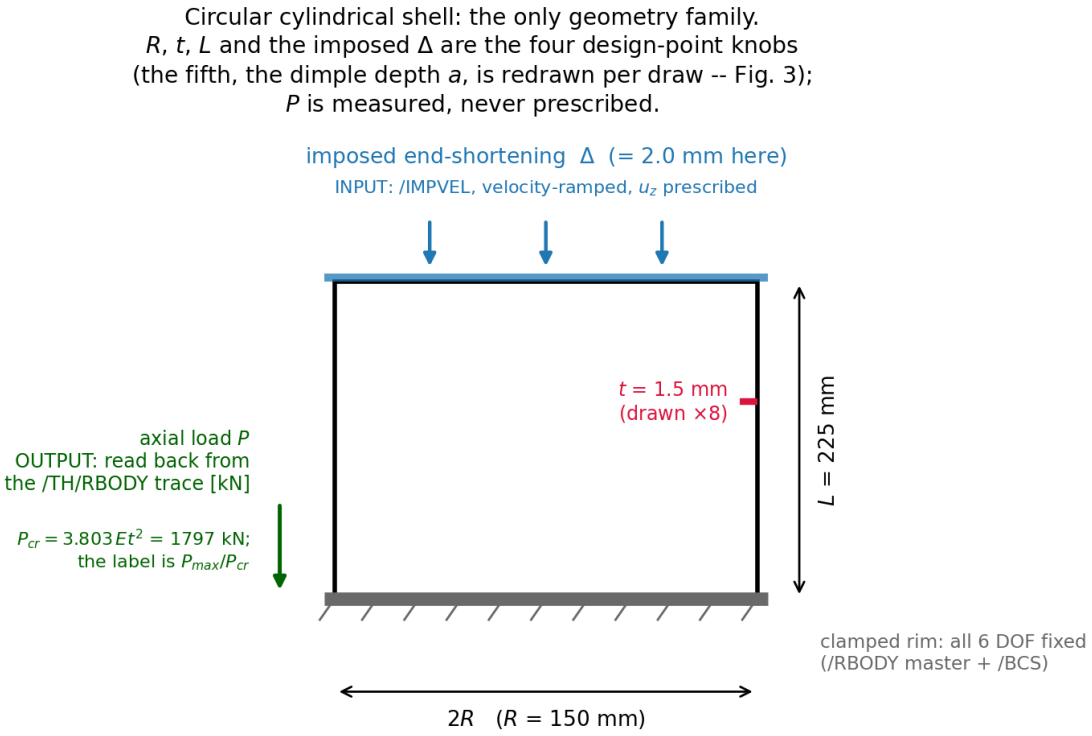


그림 6: 해석 조건. 공칭 원통 ($R = 150$, $t = 1.5$(그림에서 8 배 과장), $L = 225\,\mathrm{mm}$, 설계 공간 중심) 이다. 하단 테두리는 `/RBODY+/BCS` 로 6 자유도를 구속한다. 상단 테두리에는 `/IMPVEL` 로 축방향 변위 Δ 를 속도 $v = 0.25\,\mathrm{mm/ms}$ 로 준다. 반력 P 는 입력이 아니라 출력이며 `/TH/RBODY` 에서 읽는다. 고전 좌굴하중은 $P_{cr} = 3.803\,Et^2$(중심에서 1797 kN) 다.

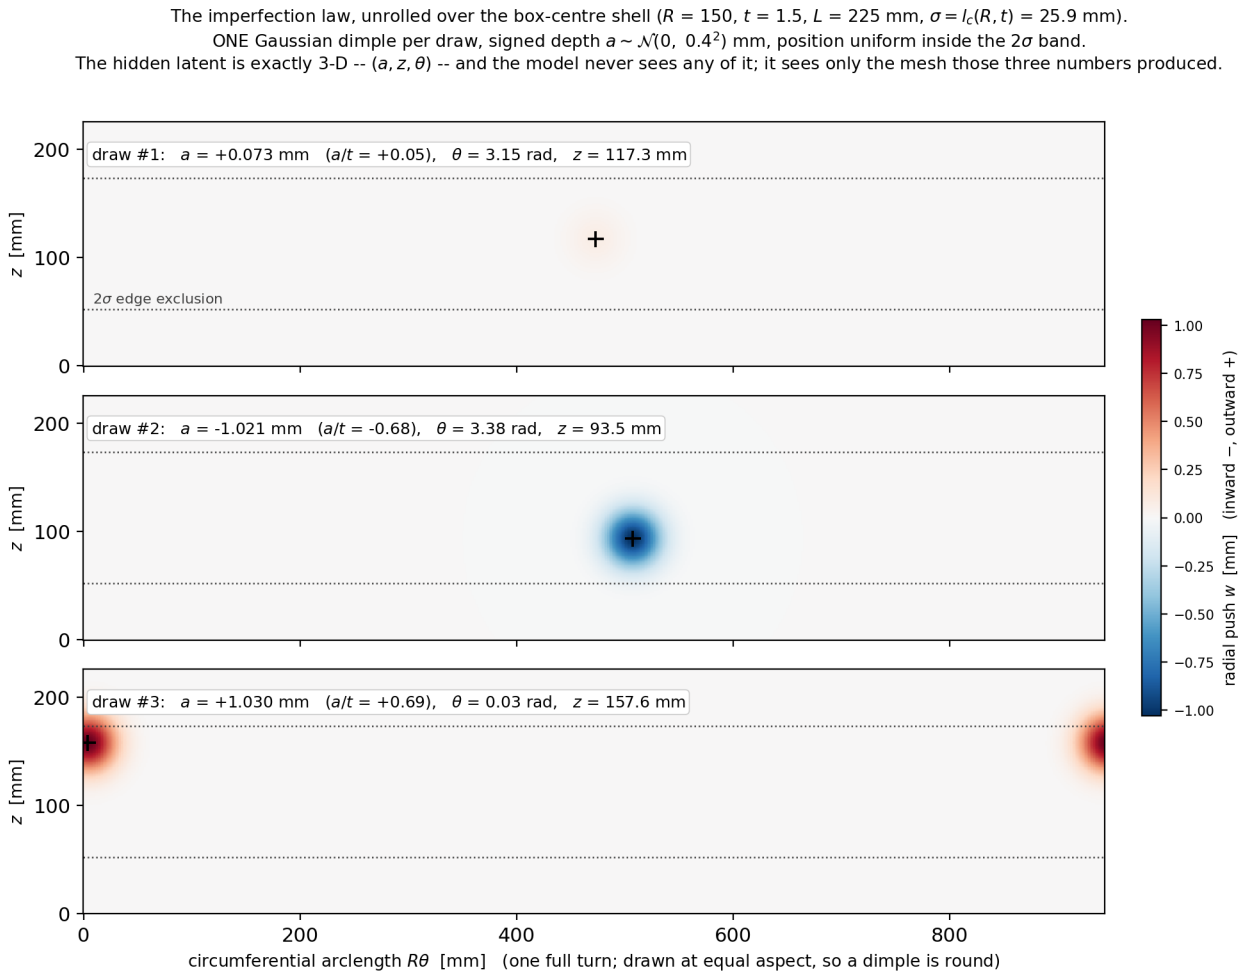


그림 7: 숨은 결함 ξ. 중심 형상의 펼친 셸 위에 그린 세 표본이다 ($a = +0.073, -1.021, +1.030\,\mathrm{mm}$). 가우시안 딤플의 폭은 $\sigma = l_c$ (중심에서 25.9 mm) 이고, 중심은 양 끝에서 2σ 떨어진 영역 (점선) 안에 균일하게 놓인다. 결함은 솔버의 초기 형상에만 들어간다. **모델 입력은 결함 없는 공칭 원통이다.**

항목	값
설계 변수	$R \sim U[100, 200]$, $t \sim U[1, 2]$, $L \sim U[150, 300]$, $\Delta \sim U[1, 3]$ (mm); 4 차원 LHS 150 형상
결함	형상당 64 표본; $a \sim \mathcal{N}(0, 0.4^2)$ mm; $\sigma = l_c = \pi\sqrt{Rt}/[12(1-\nu^2)]^{1/4}$; 중심은 2σ 끝단 배제 영역 안에서 균일, θ_c 균일
재료	선형 탄성 강 (`/MAT/ELAST`, 항복 없음), $E = 210\,\mathrm{GPa}$, $\nu = 0.3$, $\rho = 7.85 \times 10^{-6}\,\mathrm{kg/mm^3}$
요소·메시	정렬 사각 셸, QEPH, 두께 적분점 $N = 5$; $h \le l_c/10$; 24,852–87,398 노드 (중앙값 45,623)
솔버	OpenRadioss explicit, 단위계 kg–mm–ms
경계 조건	하단 테두리 6 자유도 구속; 상단 `/IMPVEL` u_z, $v = 0.25\,\mathrm{mm/ms}$(램프)
기준량	$P_{cr} = 3.803\,Et^2$; $d_{cr} = 0.60523\,tL/R$; 하중비 $\lambda = \Delta/d_{cr}$
HDF5 행	0:3 좌표, 3:6 변위 u, 6 두께 t, 7 강제변위 Δ, 8 노드 타입; `input_var 3`, `output_var 3`, `cond_var 2`
분할	`split_group_attr shape_idx`(형상 단위); test 15 형상
OOD	중심 $(150, 1.5, 225, 2.0)$ 에서 한 축만: R 80/240, t 0.8/2.4, L 120/350, Δ 0.6/3.6

표 3: 원통 셸 좌굴 (ex3) 데이터셋. 결함 $\xi = (a, z_c, \theta_c)$ 는 HDF5 의 `latent/` 그룹에 진단용으로만 저장되고, 입력 행에는 없다.

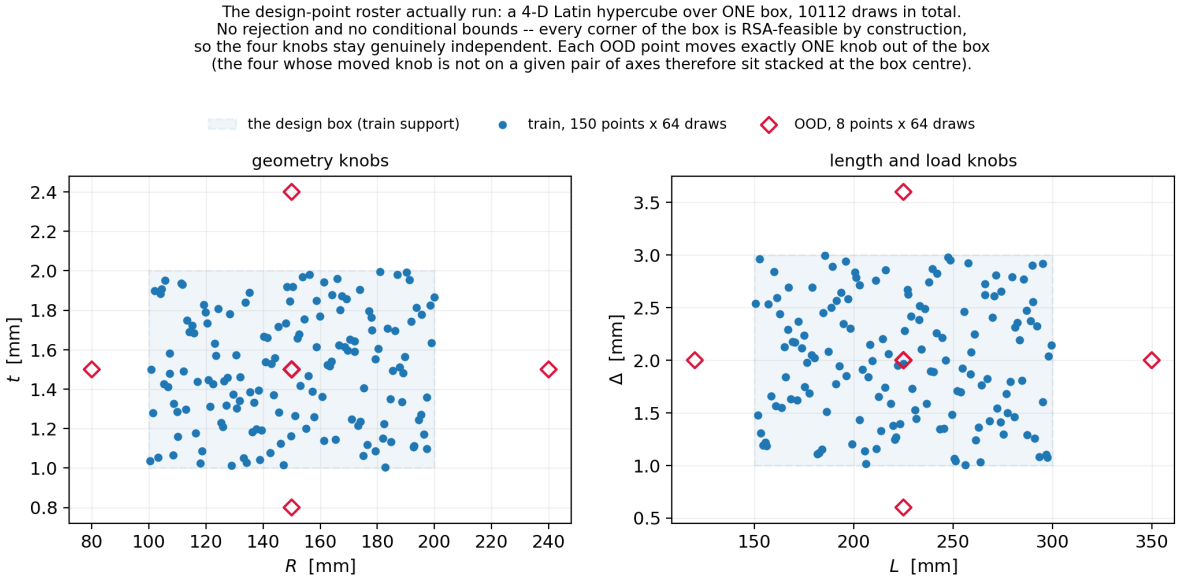


그림 8: 생성 시점의 설계 공간. 학습 150 형상 (4 차원 LHS) × 64 표본과, 중심에서 한 축만 옮긴 OOD 8 형상 × 64 표본, 모두 10,112 표본이다. 평가 때 OOD 는 형상당 200 표본으로 늘렸다 (그림 9).

공통	DDP; batch 2 × accum 4; lr 10^{-4}, wd 10^{-4}, warmup 5; augment; AMP; checkpointing; EMA 0.99; `latent_dim` 128; `voronoi_seedmean` 4096/256; `mp_per_level` 2,3,5,3,2; `hierarchy_variants` 2, `hierarchy_seed` 42; `positional_features` 4; `best_by` crps
HI-MGN-V	120 epoch; `vae_latent_dim` 32(×3 슬롯); `vae_mp_layers` 3; `graph_aware`; `alpha_recon` 1000; `lambda_mmd` 1(median); `posterior_min_std` 0.05; `beta_aux` 10; AdaLN; prior `gnn_e2e` FM, `prior_mp_layers` 3, hidden 128, `prior_nll_weight` 1, `prior_grad_to_encoder` 0; `prior_fm_steps` 30 Heun; `prior_freeze` 80
cHI-MGNflow	`latent_ch` 4; `ae_kl_weight` 1e-6; `ae_epochs` 60, `training_epochs` 120; `prior_blocks` 4; `flow_time_freqs` 16; t uniform, w uniform; `flow_steps` 30 Heun; `predict sample`; `val_flow_steps` 30, `val_num_samples` 8; `prior_global` 미지정 (`none`)

표 4: ex3 baseline 설정 (`configs/MeshGraphNets_Variational/probabilistic/ex3/baseline/config_train_himgn_v.txt`, `configs/HI_MGNFlow/probabilistic/ex3/baseline/config_train_chi_mgnflow.txt`). §10.4 의 비교는 이 두 설정으로 학습한 모델이다.

10.2 모델 설정

10.3 평가 프로토콜

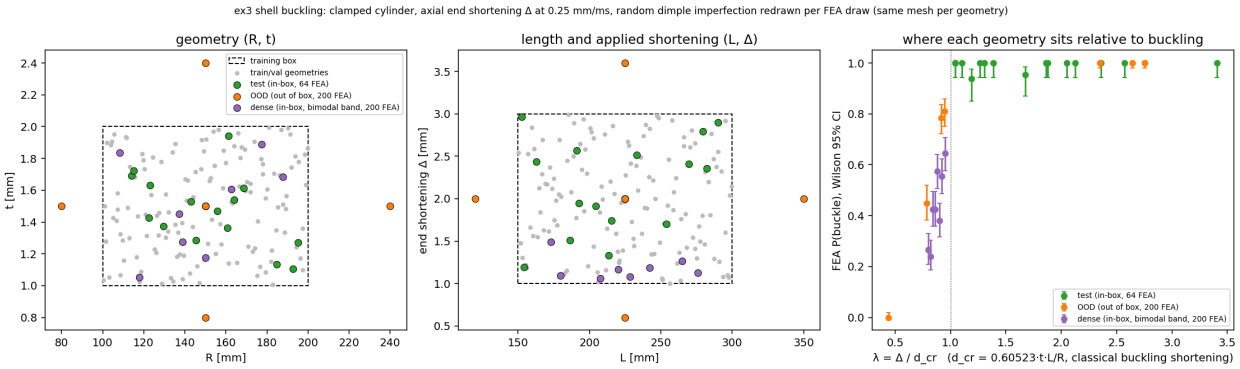


그림 9: 평가 집합. (i) test: 학습에 없던 15 형상 × FEA 64. (ii) OOD: 8 형상 × FEA 200. (iii) dense: 상자 안이지만 전이 구간 $\lambda = 0.80$–0.95 에 놓인 8 형상 × FEA 200. (R, t), (L, Δ) 평면의 위치와 FEA 좌굴 확률 (Wilson 95% 구간) 을 함께 보였다.

통계량. 표본마다 최대 노드 변위 크기 $s = \max_i \|u_i\|$ 를 쓴다. 좌굴 판정 문턱은 5.17 mm 다. 이 문턱은 비좌굴 표본의 최댓값과 좌굴 표본의 최솟값 사이에서 정했으며, 솔버의 좌굴 플래그와 4159 표본 중 97.5% 에서 일치한다 (OOD 표본 하나는 시간 초과로 빠졌다).

지표. 형상마다 모델 표본 1000 개와 FEA 표본을 비교한 뒤, 집합별로 평균한다. 아래에서 $\mathrm{sd}_{\mathrm{FEA}}$ 는 FEA 표본의 표준편차다.

- 평균비: $\bar{s}_{\mathrm{model}}/\bar{s}_{\mathrm{FEA}}$.
- sd 비: $\mathrm{sd}_{\mathrm{model}}/\mathrm{sd}_{\mathrm{FEA}}$.
- W1/sd: $W_1/\mathrm{sd}_{\mathrm{FEA}}$.
- CRPS/sd: FEA 표본마다 모델 앙상블의 CRPS 를 계산해 평균한 뒤 $\mathrm{sd}_{\mathrm{FEA}}$ 로 나눈다.
- KS: 두 경험분포 사이의 KS 통계량.
- $|\Delta P|$: $|P_{\mathrm{model}}(\mathrm{buckle}) - P_{\mathrm{FEA}}(\mathrm{buckle})|$.

노이즈 바닥. FEA 표본 수가 유한하므로 완벽한 모델도 0 을 얻지 못한다. 바닥은 FEA 표본을 반으로 나눠 서로 비교해 구한다. W1/sd 바닥은 FEA 표본 수에 따라 다음과 같다 (평균 / 90 분위).

FEA 표본 수	16	32	64	100
W1/sd	0.263 / 0.455	0.189 / 0.329	0.151 / 0.265	0.144 / 0.245

완벽한 모델의 CRPS/sd 는 약 0.52–0.54 다.

10.4 결과

관찰.

집합	모델	평균비	sd 비	W1/sd	CRPS/sd	KS	$\lvert\Delta P\rvert$
test (15×64)	cHI-MGNflow	**1.018**	0.664	**0.692**	**0.756**	**0.389**	**0.005**
	HI-MGN-V	0.832	1.251	1.375	1.003	0.541	0.087
	바닥			0.290	0.538	0.213	
OOD (8×200)	cHI-MGNflow	**1.068**	0.486	**0.829**	**0.838**	**0.500**	**0.100**
	HI-MGN-V	0.795	1.064	1.630	1.370	0.698	0.158
	바닥			0.141	0.511	0.104	
dense (8×200)	cHI-MGNflow	1.122	0.531	**0.501**	**0.649**	**0.418**	**0.100**
	HI-MGN-V	0.627	0.659	0.557	0.666	0.425	0.276
	바닥			0.112	0.524	0.096	

표 5: 최대 변위 $s = \max_i \|u_i\|$ 의 형상별 분포 비교 (모델 표본 1000/형상, 집합 평균). 평균비와 sd 비의 목표는 1 이고, 나머지는 바닥에 가까울수록 좋다. 형상별 값은 부록 A 에 있다.

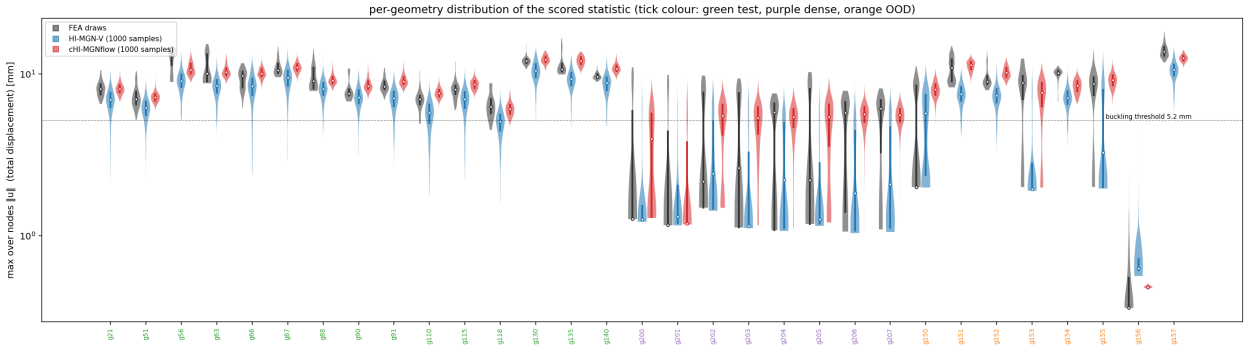


그림 10: 형상별 최대 변위 분포 (로그 축). FEA, HI-MGN-V(1000 표본), cHI-MGNflow(1000 표본) 이고, 점선은 좌굴 문턱 5.2 mm 다. cHI-MGNflow 는 중심은 맞지만 폭이 좁다. HI-MGN-V 는 전체가 아래로 밀려 있고, 큰 분기에 가야 할 질량이 아래 꼬리에 남는다.

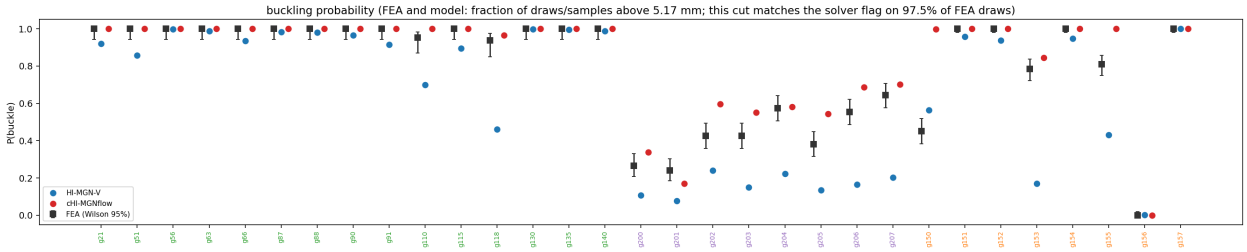


그림 11: 형상별 좌굴 확률. FEA 는 Wilson 95% 구간과 함께 보였다. 문턱 5.17 mm 는 솔버 플래그와 97.5% 일치한다.

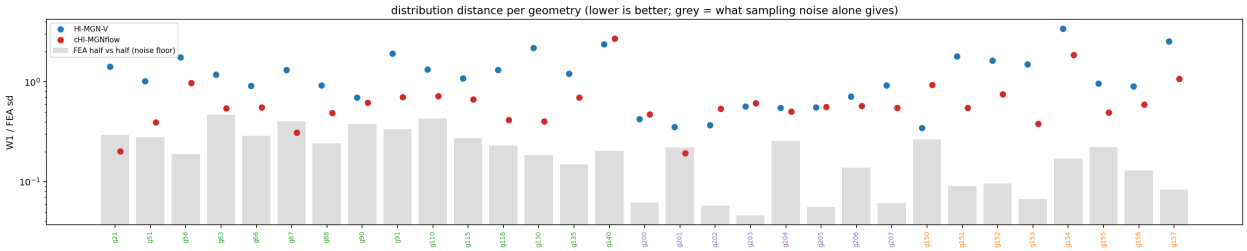


그림 12: 형상별 W1/sd. 회색은 FEA 반-대-반 노이즈 바닥이다.

1. **test 와 OOD 에서는 cHI-MGNflow 가 분명히 낫다.** test W1/sd 는 0.69 대 1.38 이고, OOD CRPS/sd 는 0.84 대 1.37 이다. 두 모델이 틀리는 방식은 다르다.
   - cHI-MGNflow 는 평균이 맞고 (1.02) 폭이 좁다. sd 비는 평균 0.66 이고 중앙값은 0.58 이다. g140 의 1.65 가 평균을 끌어올렸다.
   - HI-MGN-V 는 평균이 0.83 배로 작다. sd 비가 1 을 넘는 것 (1.25) 은 폭이 맞아서가 아니다. 잘못된 분기 쪽으로 긴 아래 꼬리가 생겨서다 (그림 10).
2. **좌굴 확률.** cHI-MGNflow 는 좌굴을 과대 예측한다. 예를 들어 g150 은 1.00 대 FEA 0.45 이고, g155 는 1.00 대 0.81 이다. HI-MGN-V 는 dense 구간에서 과소 예측한다 (0.08–0.24 대 FEA 0.24–0.65).
3. **dense 구간에서는 거의 비긴다.** W1/sd 는 0.50 대 0.56, CRPS/sd 는 0.65 대 0.67, KS 는 0.42 대 0.42 다. 차이는 $|\Delta P|$(0.10 대 0.28) 와 평균비 (1.12 대 0.63) 에 있다.
4. 이전 평가도 같은 방향이다. OOD 8 형상 × 64, 통계량 u_x 범위로 비교한 결과는 다음과 같다.

	CRPS/sd	평균 편차/sd	sd 비	PIT KS	W1/sd
cHI-MGNflow	0.360	−0.01	0.81	0.28	0.22
HI-MGN-V	0.664	−0.69	0.71	0.62	0.69

HI-MGN-V 표본에 test split 에서 맞춘 단일 배율 $\alpha = 1.45$ 를 곱하면 OOD CRPS/sd 가 0.385, W1/sd 가 0.31 로 내려간다. 즉 HI-MGN-V 오차의 상당 부분은 전체 진폭의 축소다.

10.5 HI-MGN-V 진단: 인코더가 병목이다

전체 모델.

- 학습 표본을 posterior 평균으로 디코딩하면 진폭이 FEA 의 0.72 배다 (중앙값, 범위 0.56–0.81).
- 설명 비율은 1 – 재구성 MSE/z 없는 바닥 MSE 로 정의한다. 바닥은 형상별 표본 평균 필드로 예측했을 때의 MSE 다.
- 검증 재구성 0.287, 바닥 0.540 이므로 z 는 표본 간 변동의 약 47% 만 설명한다. 바닥은 train 0.529, val 0.540, test 0.683 이다.

20 형상 부분실험. 그림 1(c) 의 20 개 형상으로 세 arm 을 비교했다.

- 분할은 16/2/2, batch 1 × accum 8, 100 epoch, `prior_freeze 0` 이다.
- 배치 1 이라 MMD 는 상수다. VRAM 은 batch 1 기준이다.
- 바닥은 train 0.535, valid 1.012, test 0.475 다.

arm	train 재구성	valid 재구성	CRPS	바닥 탈출 epoch	VRAM
base (`vae_mp_layers 3`, z 32)	0.529	1.138	0.615	탈출 못 함	10.3 GB
mp8 (8, 32)	0.288	0.854	0.529	35	14.2 GB
mp8z128 (8, 128)	0.286	0.850	0.541	35	—

인코더 깊이를 3 에서 8 로 늘려야만 재구성이 바닥 아래로 내려간다. 잠재 크기를 32 에서 128 로 늘리는 것은 효과가 없다. 즉 병목은 잠재 용량이 아니라 인코더의 수용영역이다.

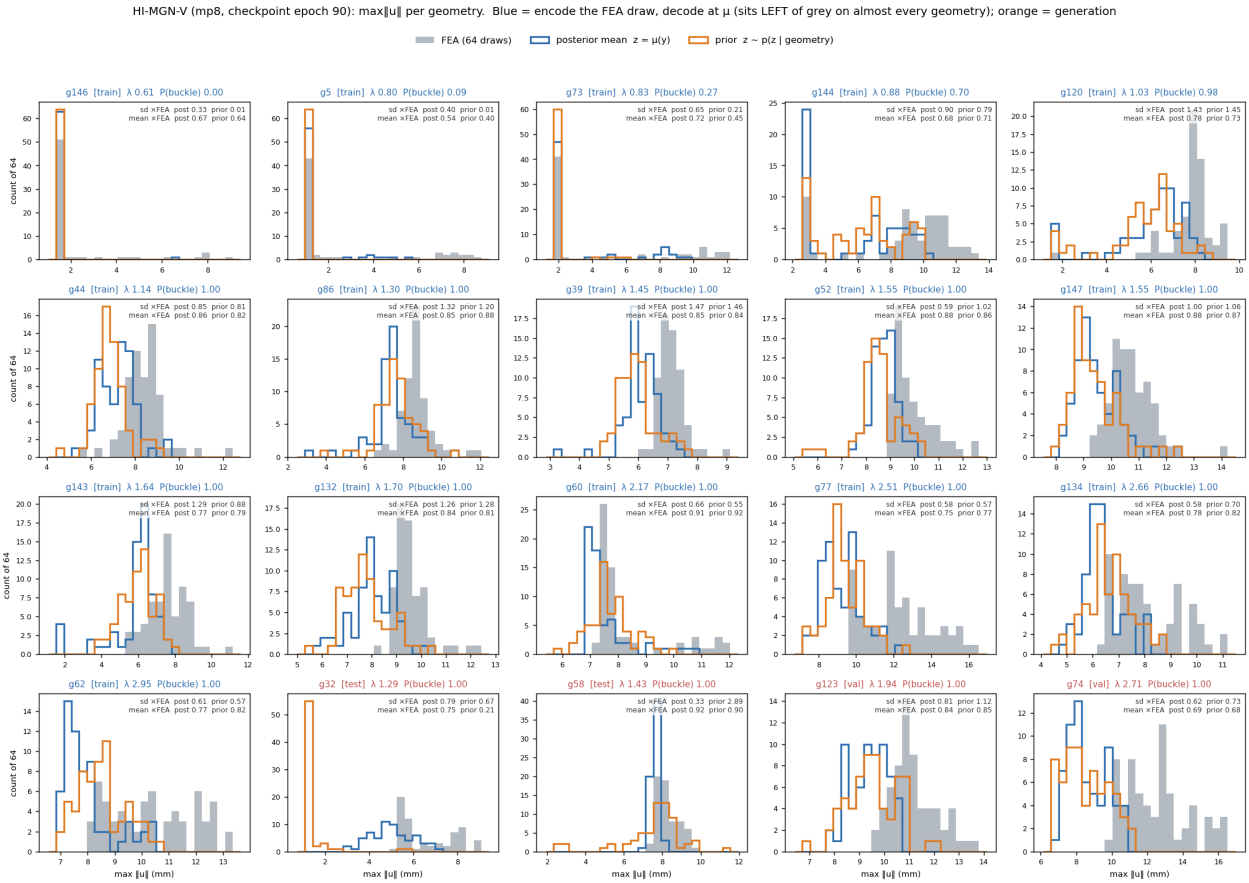


그림 13: mp8 arm, epoch 90 의 20 형상 히스토그램. 회색은 FEA, 파랑은 posterior 평균 디코딩, 주황은 prior 표본이다. 각 패널에 sd 비와 평균비를 적었다.

mp8 의 epoch 90 지표 (train 16 / held 4 형상) 는 다음과 같다.

- posterior 평균 진폭: 0.78 / 0.80.
- posterior sd 비: 0.75 / 0.70.
- 형상 내 기울기 (디코딩 통계량 대 참값): 0.40 / 0.23.
- 설명 비율: 0.41 / 0.01.

양봉 학습 형상 (g5, g73, g144, g146) 에서는 큰 분기 표본 100 개 중 39 개가 작은 분기로 디코딩된다. 맞는 분기로 간 표본의 진폭은 0.84 배다. prior 는 대체로 posterior 와 비슷하다. 예외로 g146 과 g5 에서는 붕괴한다 (sd 0.01). g32 에서는 prior 표본 64 개 중 55 개가 잘못된 분기로 간다. base arm 의 설명 비율은 0.01 / −0.10, 진폭은 0.35 / 0.31 이다.

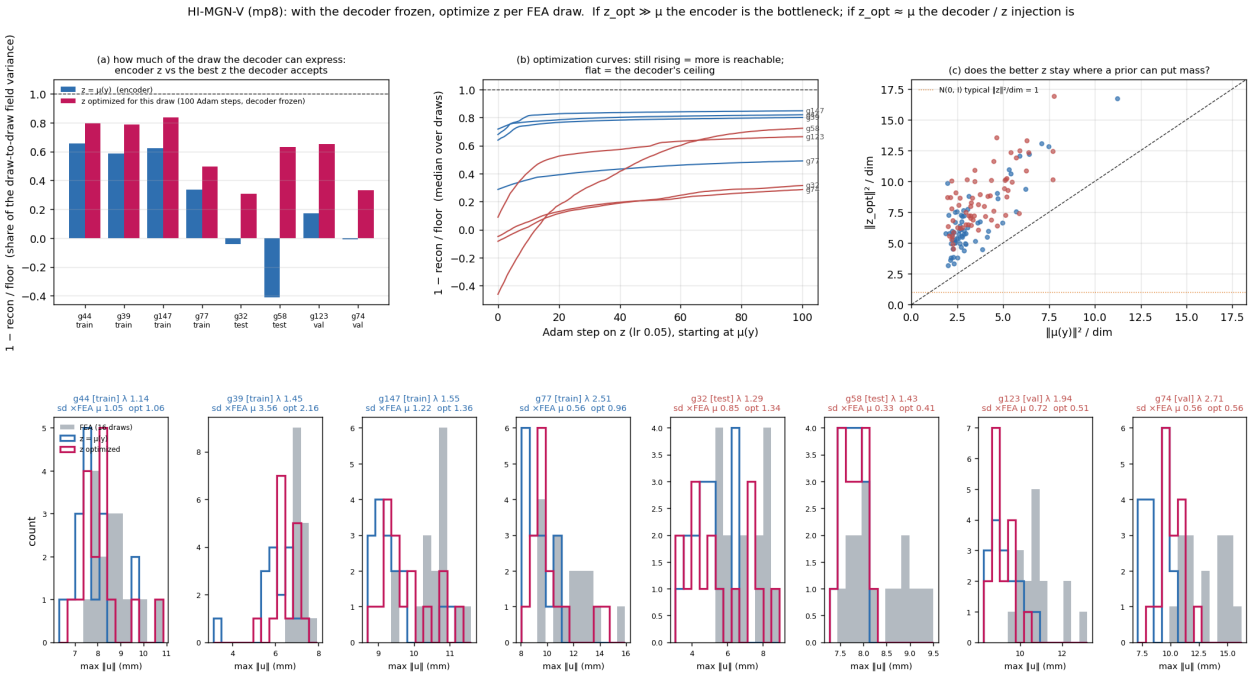


그림 14: 같은 디코더에서 z 를 직접 최적화한 결과 (형상 8 개, Adam 100 스텝, lr 0.05). (a) posterior 평균 μ 와 최적화된 z_{opt} 의 설명 비율. (b) Adam 곡선. 100 스텝에서 평탄하다. (c) $\|z_{\text{opt}}\|^2/\dim$ 대 $\|\mu\|^2/\dim$. 아래 줄은 FEA 16 표본과 비교한 히스토그램이다.

z 최적화. 디코더를 고정하고 표본마다 z 를 직접 최적화했다.

	설명 비율 $\mu \to z_{\text{opt}}$	진폭 $\mu \to z_{\text{opt}}$
train	0.34–0.66 → 0.49–0.84	0.78–0.90 → 0.87–0.94
held	−0.41–0.17 → 0.31–0.65	0.67–0.92 → 0.77–0.93

$\|z_{\text{opt}}\|^2/\dim$ 은 $\|\mu\|^2/\dim$ 의 약 2 배다. 이 결과에서 세 가지를 읽을 수 있다.

1. 같은 디코더로 훨씬 더 설명할 수 있으므로, **주 병목은 인코더**다.
2. 최적화해도 설명 비율은 0.85 이하에 머문다. 공간적으로 균일한 전역 주입에는 표현력 상한이 있다.

3. z_{opt} 는 posterior 구름 밖에 있다. 따라서 이 차이를 prior 만 개선해서 메울 수는 없다.

10.6 cHI-MGNflow 진단: prior 가 노드 간 결합을 잃는다

설정. 동결된 AE 위에서 `train_prior` 로 `prior_blocks 16` prior 를 학습했다. 형상 24 개 (train 9 / test 15) 에 FEA 각 32 표본이다. 네 가지 잠재를 같은 디코더로 디코딩한다. μ_r 은 FEA 표본 r 의 posterior 평균이다.

- posterior 평균: μ_r.
- prior: flow ODE 로 얻은 z_1'.
- shuffle: coarse 노드마다 독립적으로 고른 표본 r_i 의 $\mu_{r_i,i}$. 노드별 주변분포는 posterior 와 같고 노드 간 결합은 없다.
- coherent: $\bar{\mu} + \sum_r w_r(\mu_r - \bar{\mu})$, $w \sim \mathcal{N}(0, 1/(R-1))$. posterior 의 노드 간 전체 공분산을 가진 가우시안이다. 정답 표본이 필요한 오라클이다.

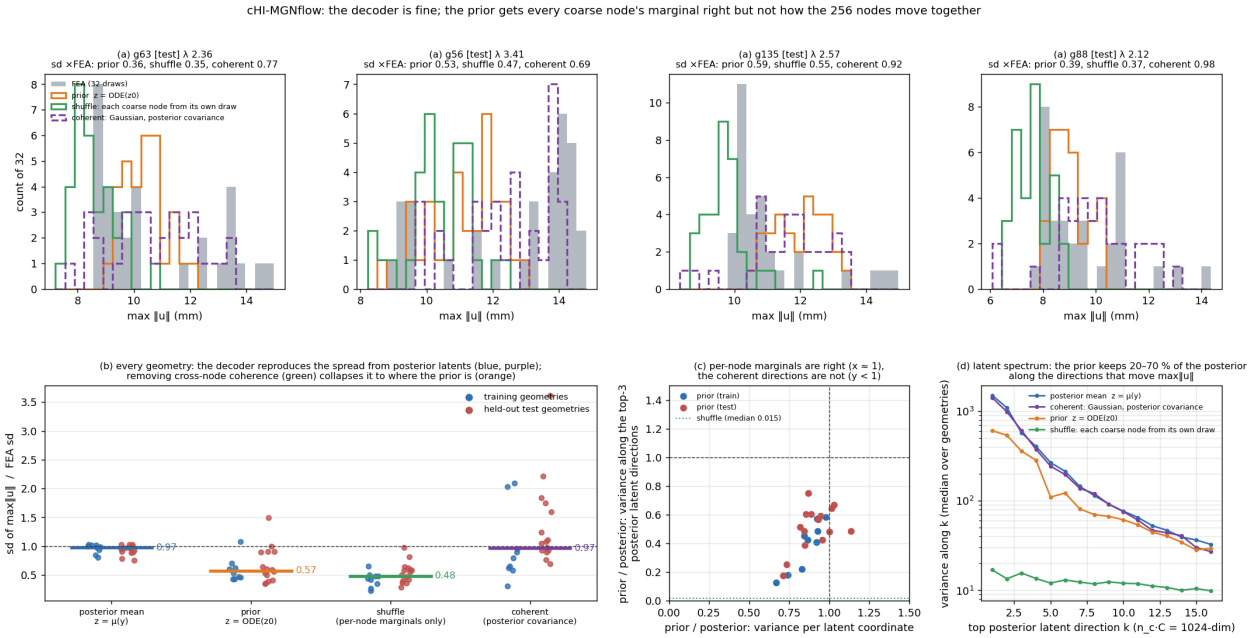


그림 15: cHI-MGNflow 진단. (a) g63, g56, g135, g88 의 히스토그램 (FEA 32). prior, shuffle, coherent 를 비교했다. (b) sd 비 중앙값. posterior 평균 0.97, prior 0.57, shuffle 0.48, coherent 0.97. (c) 좌표별 분산비는 약 1 이지만, 상위 3 개 주성분 방향의 분산비는 1 보다 작다 (shuffle 중앙값 0.015). (d) 잠재 스펙트럼. prior 는 상위 방향에서 posterior 분산의 20–70% 만 갖는다.

sd 비	posterior 평균	prior	shuffle	coherent
train	0.99	0.53	0.44	0.79
test	0.97	0.59	0.55	1.08

- posterior 평균비는 1.00 이다. 즉 오토인코더는 정확하다.
- prior 잠재의 좌표별 분산비는 0.86 / 0.89 로 거의 맞다. 상위 3 개 주성분 방향의 분산비는 0.42 / 0.51 에 그친다.

- prior 는 shuffle 과 비슷하고, coherent 는 FEA 와 비슷하다. 따라서 디코더는 정상이다. 실패는 prior 가 **노드 사이의 결합**을 재현하지 못하는 데 있다. 노드마다는 그럴듯하지만 서로 맞지 않는 잠재가 나오고, 디코더는 이를 두 분기 사이의 필드로 만든다.
- 블록을 4 에서 16 으로 늘린 효과는 작다. sd 비 기하평균이 train 0.49 → 0.55, test 0.59 → 0.62 이고, 검증 CRPS 는 둘 다 0.281 이다.
- flow 스텝을 30 에서 100 으로 늘려도 결과가 같다. 검증 CRPS 는 prior epoch 10 부터 약 0.28 에서 정체한다.

수용영역을 넓혀도 4 hop 에서 16 hop 으로 늘어날 뿐이다. 이 진단이 §7 의 전역 토큰을 추가한 직접적인 근거다. 원래 test split 에서 측정한 값 (prior sd 비 중앙값 0.77, 범위 0.39–1.23) 도 같은 방향이다.

10.7 두 번째 데이터: SAOI 휨

사내 SAOI 보드 휨 (warpage) 데이터는 평가 집합 하나가 부품 하나의 공정 실현 125 개다. 따라서 sd 비의 목표는 1 이다. 통계량은 z 변위의 peak-to-valley 다.

2026-09 비교 (각 모델 8-arm 2^{4-1} 스윕, 1000 epoch).

- MGN-V 가 최고 W1/sd 0.410 으로, cHI-MGNflow 의 0.896 보다 2.2 배 낫다. MGN-V arm 2 가 GPU 고장으로 빠져 있다는 점은 감안해야 한다.
- 두 모델 모두 퍼짐이 2 배 정도 좁다. sd 비 최대가 0.526 / 0.769 다.
- cHI-MGNflow 의 실패는 한 부품군에 몰려 있고, 순수한 평균 편향이다 (1.4–3.6σ). 편향의 부호가 부품군마다 뒤집힌다.
- t 표본화는 uniform 이 logitnormal 보다 낫다 (Δ 0.333). `prior_grad_to_encoder` 의 효과는 Δ 0.001 로 없다.

ex3 에서는 순위가 뒤집힌다. 이 수치는 이전 스윕 설정에서 나온 것이며, 현재 `SAOI_run` 설정으로는 재현되지 않는다.

2026-10 토큰 스윕. `tok` 은 학습 부품의 실현 분포는 잘 맞추지만, 처음 보는 부품에서는 폭과 모양이 모두 어긋난다. SAOI 는 표본 단위 분할 (`split_seed 42`) 이라 검증 집합에 이미 본 부품이 들어간다. `best_by crps` 는 가장 많이 외운 epoch 을 고르게 된다. 따라서 이 결과는 용량보다 과적합 문제로 읽는 것이 맞다. 형상 단위 분할 arm(`tok_grp`) 을 만들었고, 아직 실행하지 않았다.

10.8 진행 중: ex3 토큰 스윕

§7 의 8 arm 스윕은 결과를 기다리고 있다. 성공 기준은 세 가지다.

- prior sd 비가 약 0.9 에 이른다.
- 상위 3 개 주성분 분산비가 약 0.9 에 이른다.
- 히스토그램에서 두 분기 사이의 질량이 사라진다.

넘어야 할 held-out 기준선은 u_x 범위 기준 sd 비 0.81, CRPS/sd 0.36, W1/sd 0.22 다.

11 한계와 열린 문제

- **단일 추론 계층.** 추론은 `hierarchy_seed 42` 로 만든 분할 하나만 쓰고, 그 분할은 학습 캐시에 없다. HI-MGN 계열은 FPS 시작 노드에 민감하다 (노드 번호를 바꾸면 최대 $|u_z|$ 가 약 8% CV 로 움직인다). 분할에 따른 분산은 아직 측정하지 않았다.
- **잠재 평균은 필드 평균이 아니다.** `predict mean` 은 $D(\mathbb{E}[z])$ 다. 분기 문제에서 결정론적 요약이 필요하면 `ensemble_mean` 을 써야 한다.
- **MMD 가 꺼져 있다.** HI-MGN-V 의 MMD 는 배치 내 표본으로만 계산한다. GPU 당 배치가 2 이하인 baseline 에서는 상수다. 집계 posterior 를 $\mathcal{N}(0, I)$ 로 당기는 힘이 사실상 없고, 동결 시점의 z 표준화가 이를 대신한다.
- **PV 보조 손실과 평가 통계량이 다르다.** 보조 손실은 u_z 의 peak-to-valley 에 걸리지만, 평가는 $\max \|u\|$ 로 한다.
- **단일 시드.** `training_seed` 는 쓰이지 않는다. 모든 수치는 학습 1 회분이다. 노이즈 바닥은 같은 설정을 반복해야만 얻을 수 있다.
- **입력은 공칭 형상뿐이다.** 결함이 입력에 없다는 것이 문제 정의이므로, 결함 정보를 쓰는 비교 (조건부 결정론 모델) 는 하지 않았다.
- **잠재 정규화가 없다.** LDGN 과 달리 cHI-MGNflow 의 잠재에는 정규화 층이 없다. KL 10^{-6} 만으로 척도가 정해진다.
- **전역 토큰은 미검증이다.** 하이브리드의 효과는 아직 측정되지 않았다. SAOI 에서는 과적합 신호가 먼저 보였다.

12 코드 위치

- HI-MGN-V: `methods/MeshGraphNets_Variational/`. 인코더와 MMD 는 `model/vae.py` 에 있다.
- cHI-MGNflow: `methods/HI_MGNFlow/`.
  - `model/CHiMGNFlow.py`: 조립, `generate`.
  - `model/autoencoder.py`: `MultiscaleDecoder`, `LatentFlowPrior`.
  - `model/blocks.py`: GnBlock, `UnpoolBlock`, `AdaLNZero`.
  - `model/flow.py`: t 표본화, 가중, `flow_det_prob`.

  운영 문서는 `methods/HI_MGNFlow/README.md` 다.
- 설정: `configs/MeshGraphNets_Variational/probabilistic/ex3/`, `configs/HI_MGNFlow/probabilistic/ex3/`(baseline, b300_sweep).
- 평가 산출물: `output/dataset_matrix/probabilistic/ex3/dense_compare/final_umag/dense_scores.json`.

참고문헌

[1] T. Pfaff, M. Fortunato, A. Sanchez-Gonzalez, P. W. Battaglia. Learning Mesh-Based Simulation with Graph Networks. ICLR, 2021.

[2] M. Fortunato, T. Pfaff, P. Wirnsberger, A. Pritzel, P. Battaglia. MultiScale MeshGraphNets. ICML AI4Science Workshop, 2022.

[3] Y. Cao, M. Chai, M. Li, C. Jiang. Efficient Learning of Mesh-Based Physical Simulation with Bi-Stride Multi-Scale Graph Neural Network. ICML, 2023.

[4] M. Lino, T. Pfaff, N. Thuerey. Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks. ICLR, 2025. arXiv:2504.02843.

[5] M. Lino, N. Thuerey. (SAR) arXiv:2604.11403, 2026.

[6] D. P. Kingma, M. Welling. Auto-Encoding Variational Bayes. ICLR, 2014.

[7] T. N. Kipf, M. Welling. Variational Graph Auto-Encoders. NeurIPS Bayesian Deep Learning Workshop, 2016.

[8] S. Zhao, J. Song, S. Ermon. InfoVAE: Balancing Learning and Inference in Variational Autoencoders. AAAI, 2019.

[9] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, A. Smola. A Kernel Two-Sample Test. JMLR, 2012.

[10] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, M. Le. Flow Matching for Generative Modeling. ICLR, 2023.

[11] X. Liu, C. Gong, Q. Liu. Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow. ICLR, 2023.

[12] P. Esser et al. Scaling Rectified Flow Transformers for High-Resolution Image Synthesis. ICML, 2024.

[13] E. Perez, F. Strub, H. de Vries, V. Dumoulin, A. Courville. FiLM: Visual Reasoning with a General Conditioning Layer. AAAI, 2018.

[14] W. Peebles, S. Xie. Scalable Diffusion Models with Transformers. ICCV, 2023.

[15] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, G. E. Dahl. Neural Message Passing for Quantum Chemistry. ICML, 2017.

[16] P. W. Battaglia et al. Relational Inductive Biases, Deep Learning, and Graph Networks. arXiv:1806.01261, 2018.

[17] T. Gneiting, A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. JASA, 2007.

[18] C. A. T. Ferro. Fair Scores for Ensemble Forecasts. QJRMS, 2014.

A 형상별 결과

형상	R	t	L	Δ	λ	n_{FEA}	P FEA / cHI / V	평균비 cHI / V	sd 비 cHI / V	W1/sd cHI / V	바닥
test											
g21	114	1.69	204	1.91	1.04	64	1.00 / 1.00 / 0.92	1.00 / 0.85	0.72 / 1.42	0.20 / 1.42	0.29
g51	130	1.37	186	1.51	1.26	64	1.00 / 1.00 / 0.86	0.99 / 0.84	0.46 / 0.88	0.39 / 1.01	0.28
g56	156	1.47	153	2.96	3.41	64	1.00 / 1.00 / 1.00	0.86 / 0.72	0.50 / 0.71	0.97 / 1.77	0.19
g63	164	1.54	191	2.57	2.36	64	1.00 / 1.00 / 0.99	0.95 / 0.77	0.40 / 0.60	0.54 / 1.18	0.47
g66	123	1.63	282	2.36	1.04	64	1.00 / 1.00 / 0.94	1.08 / 0.88	0.58 / 1.38	0.55 / 0.91	0.29
g87	115	1.72	280	2.79	1.10	64	1.00 / 1.00 / 0.98	1.00 / 0.85	0.62 / 1.36	0.31 / 1.31	0.40
g88	122	1.43	163	2.44	2.12	64	1.00 / 1.00 / 0.98	0.96 / 0.84	0.42 / 0.75	0.49 / 0.92	0.24
g90	161	1.94	193	1.94	1.39	64	1.00 / 1.00 / 0.96	1.06 / 0.89	0.60 / 0.90	0.62 / 0.70	0.38
g91	195	1.27	216	1.74	2.05	64	1.00 / 1.00 / 0.92	1.07 / 0.82	0.89 / 1.50	0.70 / 1.91	0.34
g110	185	1.13	214	1.33	1.68	64	0.95 / 1.00 / 0.70	1.10 / 0.81	0.57 / 1.23	0.72 / 1.33	0.43
g115	161	1.36	254	1.70	1.30	64	1.00 / 1.00 / 0.89	1.08 / 0.86	0.58 / 1.29	0.67 / 1.08	0.27
g118	143	1.53	154	1.19	1.19	64	0.94 / 0.96 / 0.46	0.94 / 0.78	0.53 / 0.88	0.42 / 1.32	0.23
g130	146	1.28	290	2.90	1.88	64	1.00 / 1.00 / 1.00	1.02 / 0.87	0.96 / 2.08	0.40 / 2.17	0.18
g135	193	1.11	270	2.41	2.57	64	1.00 / 1.00 / 0.99	1.06 / 0.82	0.46 / 0.77	0.70 / 1.21	0.15
g140	169	1.61	233	2.52	1.86	64	1.00 / 1.00 / 0.99	1.12 / 0.90	1.65 / 3.02	2.70 / 2.38	0.20
OOD											
g150	80	1.50	225	2.00	0.78	200	0.45 / 1.00 / 0.56	1.61 / 1.07	0.27 / 0.77	0.93 / 0.34	0.26
g151	240	1.50	225	2.00	2.35	200	1.00 / 1.00 / 0.96	1.04 / 0.70	0.45 / 0.64	0.55 / 1.80	0.09
g152	150	0.80	225	2.00	2.75	199	1.00 / 1.00 / 0.94	1.09 / 0.78	0.67 / 0.97	0.75 / 1.62	0.10
g153	150	2.40	225	2.00	0.92	200	0.79 / 0.84 / 0.17	0.91 / 0.39	0.71 / 0.68	0.38 / 1.50	0.07
g154	150	1.50	120	2.00	2.75	200	1.00 / 1.00 / 0.95	0.85 / 0.72	1.01 / 1.31	1.86 / 3.38	0.17
g155	150	1.50	350	2.00	0.94	200	0.81 / 1.00 / 0.43	1.17 / 0.63	0.31 / 1.07	0.50 / 0.96	0.22
g156	150	1.50	225	0.60	0.44	200	0.00 / 0.00 / 0.00	0.98 / 1.32	0.03 / 2.00	0.60 / 0.90	0.13
g157	150	1.50	225	3.60	2.64	200	1.00 / 1.00 / 1.00	0.90 / 0.76	0.44 / 1.07	1.07 / 2.53	0.08
dense											
g200	163	1.61	265	1.27	0.80	200	0.27 / 0.34 / 0.11	1.11 / 0.58	0.63 / 0.50	0.47 / 0.42	0.06
g201	177	1.89	220	1.16	0.82	200	0.24 / 0.17 / 0.08	0.81 / 0.67	0.70 / 0.50	0.19 / 0.36	0.22
g202	108	1.84	173	1.49	0.84	200	0.42 / 0.60 / 0.24	1.15 / 0.76	0.60 / 0.66	0.54 / 0.37	0.06
g203	150	1.18	276	1.13	0.86	200	0.42 / 0.55 / 0.15	1.25 / 0.57	0.50 / 0.65	0.61 / 0.57	0.05
g204	118	1.05	228	1.08	0.88	200	0.57 / 0.58 / 0.22	1.20 / 0.69	0.51 / 0.82	0.50 / 0.55	0.26
g205	188	1.69	242	1.18	0.90	200	0.38 / 0.54 / 0.14	1.16 / 0.54	0.58 / 0.53	0.56 / 0.56	0.06
g206	139	1.28	207	1.06	0.92	200	0.56 / 0.69 / 0.17	1.22 / 0.61	0.38 / 0.77	0.57 / 0.71	0.14
g207	137	1.45	180	1.09	0.95	200	0.65 / 0.70 / 0.20	1.09 / 0.58	0.35 / 0.84	0.55 / 0.92	0.06

표 6: 형상별 결과 (`dense_scores.json`). V 는 HI-MGN-V 다. "바닥" 은 그 형상의 FEA 반-대-반 W1/sd 다. $n_{\mathrm{FEA}} = 64$ 인 test 형상은 바닥이 크므로, 예컨대 g21 에서 cHI-MGNflow 의 0.20 은 바닥 0.29 안에 있다.

B 2026-09-18 판 대비 정정 목록

1. **추론 비용.** "샘플당 전체 V-cycle 2 회 (encode 1, decode 1)" 는 틀렸다. 하강 1 회 (10 블록) + 상승 1 회 (10 블록), 곧 V-cycle 1 회분이다 (§6.3).
2. **prior 의 백본.** "V-cycle 이 압축기와 prior 모두의 백본" 이라는 서술은 틀렸다. prior 는 G_L 위의 평탄한 GnBlock 스택이다.
3. **AdaLN-Zero 초기화.** "항등함수로 초기화" 는 틀렸다. gate 가 1 로 초기화되므로 조건 없는 블록 그대로다. LayerNorm 도 없다 (§4.2).
4. **prior 조건.** "AdaLN 이 그래프 조건·t·g 를 받음" 은 틀렸다. AdaLN 은 t 만 받고, $h_L^{\varnothing}$ 은 `in_proj` 에서 concat 된다.
5. z **lift.** "coarsest 노드 수로 lift" 는 틀렸다. 노드별 채널 변환 ($C \to D$) 이다.
6. t **표본화.** uniform 외에 logitnormal 옵션이 있다. 가중 `x0` 와 `flow_det_prob` 도 추가했다.
7. **읽기 모드.** `predict mean` 이 잠재 평균이라는 점, `ensemble_mean` 은 호출자가 필드 공간에서 평균해야 한다는 점, 자기회귀에서 매 스텝 새 z_0 를 뽑는다는 점을 추가했다.
8. **학습 모드.** `train` 의 순서 (AE → prior), 마지막 epoch AE 가 동결된다는 점, `modelpath` 를 덮어쓴다는 점, `training_seed` 가 쓰이지 않는다는 점을 추가했다.
9. **검증 지표.** "recon" 은 표본 0 번의 MSE 다. "spread" 의 분모는 참 분포의 표준편차가 아니라 정답 필드 하나의 공간 표준편차다.
10. **skip 우회 붕괴.** "LDGN VGAE collapse 와 동일" 은 과장이다. VGAE 에는 skip 이 없으므로 유사한 방향의 방지책일 뿐이다.
11. **LDGN 서술.**
    - VGAE ablation 의 원인 해석은 반대 방향으로 오독했다.
    - FM 은 App. D.7 에 실험이 있다.
    - "단일 스케일 실패" 는 필드 공간 DGN 의 결과다. LDGN denoiser 는 U-Net 이다.
    - 조건 인코더는 AE 의 모든 레벨에 조건을 넣는다.

    (§9)
12. **검증 상태.** "GPU 학습 미수행" 은 사실이 아니게 되었다. ex3 결과와 진단으로 대체했다 (§10).
13. **범위.** 단일 모델 리포트에서 HI-MGN-V 와 하이브리드 토큰을 포함한 비교 리포트로 바꿨다.