

cHI-MGNflow: 계층적 메시그래프위의 2 단계잠재 Flow-Matching 모델

AI-CAE4ALL — methods/HI_MGNFlow 내부기술리포트

2026-09-18

Abstract

메시기반시물레이션대체모델 (surrogate model) 에서, 하나의형상·경계조건이유일한정답이 아니라가능한결과들의분포에 대응하는문제 (접촉, 좌굴, 기타경로의존적물리) 가존재한다. 본 리포트는이러한문제를위해이코드베이스가채택한조건부생성모델, cHI-MGNflow 의구조를기술한다. cHI-MGNflow 는 Lino, Pfaff & Thuerey (ICLR 2025) 의논문 *Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks* 가제안한 LDGN(그논문이자신의압축-latent 변형에불인 이름) 의 2 단계설계 — 근손실없는그래프압축기 (stage 1) + 그압축된잠재위에서만동작하는 flow-matching prior(stage 2) — 를그대로채택하되, 논문자체의멀티스케일백본을이리포지토리의계층적 HI-MGN V-cycle 로대체한것이다. 이전버전 (field-space flow matching, 압축없음) 은학습·추론분포는일치시켰지만ODE 스텝마다전체 V-cycle 을다시돌려야했고 reconstruction 단계에서부터결과가맞지않았다. 본아키텍처는압축과분포일치를동시에만족시켜, 샘플당전체 V-cycle forward 를정확히 2 회 (encode 1 회, decode 1 회) 로고정하고 K-step ODE 적분은가장 coarse 한레벨하나에만국한시킨다.

1 서론

MeshGraphNets 류모델은결정론적 encode-process-decode 구조로메시위의물리량을예측한다. 그러나결과가초기미세조건이나경로에따라갈리는문제 (접촉, 좌굴모드선택등) 에서는하나의예측값이아니라조건부분포 $p(y | c)$ 를모델링해야하며, 학습과추론에서이분포로부터표본을뽑는절차자체가아키텍처의일부가된다.

이코드베이스는이문제에두가지설계로접근해왔다.

1. **MeshGraphNets-Variational** — VAE 로 posterior $q(z | y, c)$ 를학습하고, 추론용으로별도의근사 prior $p(z | c)$ 를학습한다. 두분포가정확히같은이유가없어 aggregate-posterior drift 가발생한다.
2. **cHI-MGNflow (이전버전)** — 이불일치를없애기위해필드공간에서직접 conditional flow matching 을적용했다: 학습·추론모두 $\mathcal{N}(0, I)$ 에서출발해같은 ODE 로목표분포에도달하므로 분포불일치자체가없다. 다만압축이전혀없어노드수 $\times$ output_var 전체크기에서 flow 가동작했고, ODE 적분스텝하나마다전체 V-cycle 을다시계산해야했다. 이설계는 reconstruction 단계에서부터결과가맞지않았다.

참고논문 (Lino, Pfaff & Thuerey, LDGN) 을다시검토한결과, 이논문은필드공간이아니라압축된 coarse 잠재위에서 flow matching 을수행하고있었다. 본리포트가기술하는아키텍처 (이하 v2) 는이논문의설계를그대로채택하고논문의자체멀티스케일백본만이리포지토리의 HI-MGN V-cycle 로교체한것이며, 이전버전 (v1) 을완전히대체한다.

2 관련연구

- **MeshGraphNets** (Pfaff et al., ICLR 2021) — 메시그래프위의 결정론적 encode-process-decode 시뮬레이션대체모델.
- **계층적 (멀티스케일) 확장** — 코스닝을통해만든여러레벨사이를오가며장거리상호작용을저비용으로전달하는 V-cycle 구조 (이리포지토리의 HI-MGN). 본아키텍처는이 V-cycle 을압축기·prior 양쪽의공통백본으로그대로사용한다.
- **MeshGraphNets-Variational** — 폴링된전역벡터에대한 VAE + 별도학습된 prior. 1 절에서설명한 posterior/prior 불일치의근원.
- **Flow matching** (Lipman et al., ICLR 2023) 및 **rectified flow** (Liu, Gong & Liu, ICLR 2023) — 직선경로를따라단순분포 ($\mathcal{N}(0, I)$) 를데이터분포로옮기는 continuous normalizing flow 를시뮬레이션-프리회귀만으로학습하는기법. 학습이 ODE 를한번도적분하지않고, 적분스텝수 K 는추론시점에만결정되는하이퍼파라미터라는점이이설계전체를가능하게하는전제다.
- **Diffusion Graph Networks (DGN) / LDGN** (Lino, Pfaff & Thuerey, “Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks,” ICLR 2025, arXiv:2504.02843) — 메시기반물리문제를위해 “먼저압축, 그다음생성” 을제안한다: 근손실그래프오토인코더 (VGAE) 로 coarse 잠재를만들고, 그잠재위에서만동작하는 diffusion prior 를명시적으로학습한다. 논문은압축없이필드위에서바로 diffusion 을돌리는자신의기본형 (DGN) 과, 압축후그 latent 위에서 diffusion 을돌리는변형 (LDGN) 을직접대조한다 — 이내부대조가정확히이리포트의 v_1 (필드공간) $\rightarrow v_2$ (coarse latent) 전환과같은 motivation 이다. 핵심 ablation: 같은멀티스케일구조를쓰지만명시적으로학습된 prior 가없는 VGAE(오히려더무거운 KL, 더 coarse 한 latent 를쓴) 는간단한과제에서는통하지만복잡한과제에서는여전히 collapse 한다 — 즉계층구조자체는이설계가이기는이유가아니고, 결정적요인은 “prior 를명시적으로학습시키는가” 이다. 5 절에서이논문과본구현의구체적인같은점·다른점을정리한다.
- **AdaLN-Zero** (Peebles & Xie, “Scalable Diffusion Models with Transformers”, ICCV 2023) — 조건부정보를시간에따라변하는 scale/shift/gate 로주입하고, 학습초기에는블록이항등함수가되도록 0 근처로초기화하는기법. Stage 2 prior 의트렁크블록에사용된다.

3 구조

3.1 표기

3.2 개요: 2 단계분해

```
y, c --> [ E_theta : y-aware pass ] --> (mu, logvar) --> z ~ N(mu, sigma^2)
0, c --> [ E_theta : y-blind pass ] --> per-level skips {h_1}, prior cond g
```

```
z -----+
{h_1} (blind-pass skips) -----+--> D_theta --> y_hat
```

Stage 2 (coarsest level only, frozen Stage-1):

```
g --> z0 ~ N(0,I) --[ K-step ODE integration of v_psi ]--> z1'
```

```
train:      regress v_psi toward the path velocity between z0 and the REAL z1 = z
```

```
inference: feed z1' into D_theta in place of z
```

기호	의미
$G = (V, E)$	입력메시그래프. 레벨 0(가장 fine) 부터 L (가장 coarse) 까지의 계층을 가짐
V_l	레벨 l 의 노드 집합 (코스닝으로 생성, 압축기·prior 공통)
$y \in \mathbb{R}^{ V_0 \times F}$	예측대상 물리량 (finest 레벨의 노드 필드)
c	조건 — 형상/경계조건/재료등, 노드·엣지 특성에 인코딩됨
$z \in \mathbb{R}^{ V_L \times C}$	coarse 레벨의 노드별 잠재. <code>latent_ch</code> (= C) 채널짜리 벡터가 coarsest 레벨 노드마다 하나 — 풀링된 벡터 하나가 아니다
E_θ	압축기 인코더 (공유가중치, 두 번 호출됨, 3.3 절)
D_θ	압축기 디코더
v_ψ	stage 2 의 flow-matching 속도장 (coarsest 레벨에서만 동작)

Table 1: 표기 정리




Figure 1: 계층적 V-cycle 백본. 코스닝으로 레벨 0 부터 L 까지 내려간 뒤, unpooling 과 skip 융합으로 다시 레벨 0 까지 올라온다. 압축기 (stage 1) 는 이 V 전체를 쓰고, stage 2 prior 는 맨 밑의 G_L 하나에서만 동작한다.

압축기는 전체 V-cycle (레벨 $0 \rightarrow L \rightarrow 0$) 을 쓰고, prior 는 그 V 의 가장 바닥 (coarsest 레벨) 하나에만 존재한다. 이 비대칭이 3.5 절에서 설명하는 비용 구조의 근원이다.

3.3 Stage 1 — 계층적 압축기

`HierarchyEncoder` 는 V-cycle 의 하강 (코스닝) 팔로, 각 레벨에서 `mp_per_level` 만큼 메시지 패싱을 하고 레벨 사이를 코스닝 연산자 (bi-stride / Voronoi 등, HI-MGN 백본이 이미 제공하는 것을 그대로 재사용) 로 풀링한다. 가장 coarse 한 레벨 L 에 도달하면 선형 head 가 노드별 $(\mu, \log \sigma^2)$ 를 내고, $z \sim \mathcal{N}(\mu, \sigma^2)$ 로 재파라미터화한다 — 이는 MeshGraphNets-Variational 의 “풀링된 전역 벡터 하나” 와 대비되는, 노드 별 분포를 갖는 공간적 잠재다.

같은 가중치의 E_θ 를 한 스텝에 두 번 통과시킨다:

```
outs_y = E_theta(x = [state | y          | cond | pos | ...])  -- y를 아는 pass
outs_0 = E_theta(x = [state | zeros(y) | cond | pos | ...])  -- y를 모르는(blind) pass
```

`outs_y` 의 coarsest 출력만 $(\mu, \log \sigma^2)$ 로 간다. `outs_0` 의 레벨 별 전체 출력 이 디코더의 skip 연결과 stage 2 prior 의 조건 g 로 간다. 이 분리가 핵심이다: skip 경로가 단순한 fine-level 재사용이면 디코더가 z 를 거치지 않고 skip 만으로 y 를 복원 하도록 학습 해 버릴 수 있다 (LDGN 논문 자체의 VGAE




Figure 2: Stage 1 압축기와 Stage 2 prior 의 데이터 흐름. 같은가중치의 E_θ 가 y -aware/ y -blind 두 pass 로 호출되고, y -blind pass 의 출력만 디코더의 skip 과 stage 2 의 조건 g 로 간다. Stage 2 는 가장 coarse 한 레벨 하나에서만 동작한다.

collapse 메커니즘과 동일). skip 을 만드는데 pass 자체가 y 를 구조적으로 모르기 때문에 이 우회가 불가능하고, 추론 시점에는 y 가 애초에 없으므로 이 “blind” pass 는 학습 때와 추론 때 정확히 동일하게 동작한다.

MultiscaleDecoder(V-cycle 상승 팔) 는 z (학습 때는 posterior 샘플, 추론 때는 stage 2 가적분한 샘플) 를 coarsest 레벨 노드 수로 lift 한 뒤, 레벨을 올라가며 `outs_0` 의 skip 과 융합해 $\hat{y}$ 를 만든다.

목적 함수:

$$\mathcal{L}_{\text{AE}} = \mathbb{E}_{q_\theta(z|y,c)} \left[\|D_\theta(z) - y\|^2 \right] + \beta \cdot \text{KL}(q_\theta(z | y, c) \| \mathcal{N}(0, I)) \quad (1)$$

$\beta(\text{ae_kl_weight})$ 는 아주 작게 (논문 기준 $\sim 10^{-6}$) 잡는다 — 이 압축기는 그 자체로 생성적 병목이 아니라 근손실 압축이 목적이며, KL 은 z 를 stage 2 의 목표 ($\mathcal{N}(0, I)$ 에 가까운 분포) 에 부드럽게 앵커링 하는 정도의 역할만 한다.

3.4 Stage 2 — Coarse-Latent Flow-Matching Prior

Stage 1 이 수렴하면 그 가중치를 얼려고 정된 특성 추출기로 쓴다. Stage 2 는 그 frozen 압축기가 만든 posterior 샘플 $z_1 \sim q_\theta(z | y, c)$ (gradient 없이 draw) 를 목표점으로 하는 flow-matching 속도장 v_ψ 를 coarsest 레벨 하나에서만 학습한다. 조건부 flow-matching 경로는 다음과 같다:

$$z_0 \sim \mathcal{N}(0, I), \quad s = 1 - \sigma_{\min}, \quad \sigma_{\min} = 10^{-4} \quad (2)$$

$$z_t = (1 - s t) z_0 + t z_1, \quad t \sim U[0, 1] \quad (3)$$

$$u = z_1 - s z_0 \quad (4)$$

$$v_\psi(z_t, t, g) \approx u \quad (5)$$

z_0 는 z_1 과 같은 크기 ($|V_L| \times C$) 의 노이즈 끝점, z_t 는 이들을 잇는 직선 경로 위의 점, u 는 그 경로가 갖는 속도 (회귀 목표) 다. AdaLN-Zero GnBlock 스택 (`prior_blocks` 개) 이 coarsest 레벨 그래프 + 시간 임베딩 + g 로 조건화되어 이 속도장 v_ψ 를 근사한다.

$$\mathcal{L}_{\text{prior}} = \mathbb{E}[w(t) \|v_\psi(z_t, t, g) - u\|^2], \quad w(t) = \begin{cases} 1 & \text{flow_loss_weighting} = \text{uniform} \\ (1 - st)^2 & \text{flow_loss_weighting} = \text{x0} \end{cases} \quad (6)$$

x_0 가중치는 속도 head 자체는 그대로 두고 손실 재가중만으로 $t = 0$ 근방 정확도에 학습예산을 집중시킨다.

일부 학습 그래프는 $t = 0$ 으로 고정해서 뽑는다 (`flow_det_prob`) — 이 경우 목적함수는 $\mathbb{E}[z_1 | g]$ 에 대한 순수 결정론적 회귀로 붕괴하며, 이는 3.5 절의 결정론적 readout 을 실제로 학습시키는 장치다 (추론 시점에 그냥 읽어내는 것이 아니라).

AdaLN-Zero 블록은 초기화시 항등 함수가 되도록 (gate/weight 를 0 근처로) 구성된다 — 전역 kaiming 초기화를 먼저 적용한 뒤 이 근-항등 초기화를 덮어씌우는 순서로 진행되며, 순서를 바꾸면 kaiming 초기화가 이성질을 지워버린다.

3.5 추론 경로

```
generate(c):
    g      = E_theta, blind(0, c)                # 1) encode ONCE
    z0     ~ N(0, I)                             (coarsest 레벨 크기)
    z1'    = integrate(v_psi(., ., g), z0, K steps) # 2) coarsest 레벨에서만 K번 (Heun/Euler)
    yhat   = D_theta(z1', {h_1})                 # 3) decode ONCE
```

이 경로에서 K 번 반복되는 것은 **coarsest** 레벨 하나만 다루는 작은 네트워크뿐이며, 전체 V-cycle(인코더·디코더)은 샘플 하나당 정확히 1 회씩만 호출된다. 이것이 field-space flow(레벨 0 크기에서 매 ODE 스텝마다 전체 V-cycle 을 다시 계산해야 하는) 와 이 설계 사이의 핵심적인 구조적 차이이다.

같은 학습된 네트워크에서 결정론적 readout 도 단힌 형태로 나온다: $t = 0$ 에서는 경로 위의 점이 곧 z_0 이므로 회귀 최적점은 $v_\psi^*(z_0, 0, g) = \mathbb{E}[z_1 | g] - s z_0$ 이고, 크기 1 의 Euler 스텝을 밟으면

$$z_0 + v_\psi(z_0, 0, g) = \mathbb{E}[z_1 | g] + \sigma_{\min} z_0 \quad (7)$$

즉 $\sigma_{\min}(= 10^{-4})$ 스케일의 잔차 하나만 남는 조건부 평균이다. 같은 가중치 하나가 (i) 분포를 샘플링하는 생성 모델과 (ii) 적분 없이 1 회 forward 로 끝나는 결정론적 예측기를 동시에 서빙한다.

3.6 학습 모드

Stage 1 과 stage 2 를 지나는 세 가지 경로가 있다: stage 1 만 (압축기·디코더 학습), stage 2 만 (디스크에서 완료된 stage-1 체크포인트를 불러로드한 뒤 prior 만 학습), 또는 하나의 프로세스에서 둘 다 (정해진 epoch 동안 stage 1 → 메모리 내에서 즉시 freeze → stage 2, 체크포인트 왕복 없음). 어느 시점 이든 두 파라미터 집합 중 정확히 하나만 gradient 를 받으므로, 분산 학습 래퍼는 파라미터 그래프의 한쪽 가지가 매 스텝 unused 여도 견뎌야 한다.

4 설계 근거: 왜 먼저 압축하는가

LDGN 논문의 ablation 을 정확히 인용하면: 같은 멀티스케일 구조를 쓴 **VGAE**(오히려 더 무거운 KL, 더 coarse 한 latent 를 쓴) 도 여전히 collapse 한다. 즉 계층 구조 자체는 이 설계가 이기는 이유가 아니다.

결정적인 lever 는 “ $\mathcal{N}(0, I)$ 를 직접 가정해서 샘플링하는 대신, 압축된 공간 위에서 **prior** 를 명시적으로 학습시키는 것” 이다.

	MeshGraphNets-V	cHI-MGNflow v1 (필드 공간)	cHI-MGNflow v2 (본문서)
학습시 잠재의 출처	posterior $q(z y, c)$	필요 없음 (필드에 직접 flow)	posterior $q(z y, c)$ (stage 1)
추론시 잠재의 출처	별도 학습된 근사 prior $p(z c)$ — posterior 와 불일치가 능	$\mathcal{N}(0, I) \rightarrow$ 학습된 ODE (필드 크기)	$\mathcal{N}(0, I) \rightarrow$ 학습된 ODE (coarse 잠재 크기)
압축	있음 (폴링된 벡터)	없음	있음 (coarse 레벨 노드별 벡터)
샘플당 전체 V-cycle forward	1 (prior 는 flat)	K (ODE 스텝마다)	2 (encode 1 + decode 1, K 는 coarse 레벨에서만)

Table 2: 세 설계의 비교

v1 은 이표의 “분포 일치” 는 만족했지만 “압축” 을 하지 않아 비용과 reconstruction 신뢰성 양쪽에서 문제가 있었다. v2 는 두 축을 모두 만족시키는, 논문의 ablation 이 요구하는 조합이다.




Figure 3: 샘플 하나를 생성하는데 필요한 전체 V-cycle (회색 큰박스) 호출 횟수. v1 은 매 ODE 스텝마다 전체 V-cycle 을 다시 계산해 K 회가 필요하고, v2 는 encode 1 회 + decode 1 회로 고정되며 반복은 coarsest 레벨의 작은 네트워크 (흰 작은박스) 에서만 일어난다.

5 원본 LDGN 논문과의 비교: 같은 점과 다른 점

정확한 서지 사항을 다시 밝히면, 참고 논문의 제목은 *Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks* (Lino, Pfaff & Thuerey, ICLR 2025, arXiv:2504.02843) 이다. “LDGN” 은 그 논문이 자신의 latent-압축 변형에 붙인 이름이고, 압축 없이 필드 위에서 바로 동작하는 기본형은 논문 안에서 “DGN” 이라 불린다. 즉원 논문 자체가 이미 DGN(필드 공간) vs LDGN(압축된 latent 공간) 이라는 대조를 갖고 있고, 이 대조는 정확히 본 리포트의 $v1 \rightarrow v2$ 전환과 같은 motivation 을 공유한다. 이 절은 그 LDGN 설계와 본구현 (cHI-MGNflow v2) 이 정확히 어디까지 같고 어디부터 다른지를 정리한다.

5.1 같은 점

- **2 단계 분해 자체.** 근손실 그래프 오토인코더 (VGAE) 로 먼저 압축하고, 그 압축된 latent 위에서만 별도의 생성 prior 를 명시적으로 학습한다는 큰 그림은 그대로 채택했다.

- **잠재의모양.** 잠재는 풀링된 전역 벡터 하나가 아니라, 가장 coarse 한 레벨 G_L 의 노드마다 분포 (μ_i, σ_i) 를 갖는 공간적 잠재다.
- **KL 을 아주 작게 유지.** posterior collapse 를 피하되 z 를 prior 의 목표 분포에 앵커링하는 정도로만 KL 항의 가중치를 $\beta \sim 10^{-6}$ 수준으로 아주 작게 잡는다.
- **핵심 motivating ablation.** 같은 계층 구조를 쓰지만 명시적 prior 없이 $\mathcal{N}(0, I)$ 에서 직접 샘플링하는 VGAE 는 (간단한 과제에서는 통하지만) 복잡한 과제에서 여전히 collapse 한다는 논문의 관찰을 그대로 구현의 설계 근거 (4 절) 로 인용한다.
- **생성시 비용 철학.** 비싼 전체-그래프 연산 (encode/decode) 은 샘플당 고정된 소수 회로 묶고, 반복이 필요한 샘플링 과정은 이미 압축된 latent 공간 안에 가둔다는 비용 구조의 기본 방향은 동일하다.

5.2 다른점

항목	LDGN 원본	cHI-MGNflow v2 (본 구현)
멀티스케일 백본 / coarsening	자체 U-Net 형 multi-scale GNN, Guillard 알고리즘으로 코스닝 (1D ~2 배, 2D ~4 배 압축/레벨)	이리포지토리의 기존 HI-MGN V-cycle(bi-stride/Voronoi 등) 을 그대로 재사용 — 논문의 백본 자체를 이것으로 대체한 것이 본리 포트의 출발점
압축기 인코더 구조	조건 인코더 / 노드 인코더 / 노드 디코더, 세 개의 별도 컴포넌트 — 조건 인코더가 생성 시점에 필요한 g 인코딩을 전달	하나의 HierarchyEncoder 를 같은 가중치로 두 번 (y -aware/ y -blind) 호출 — 별도의 조건 인코더 네트워크가 없다 (3.3 절)
생성 prior 의 주 형태	diffusion (DDPM 류) 이 주 모델이고 논문 실험 전부가 이 경로를 씀; flow matching 은 부록에서 “더 빠른 샘플링” 을 위한 미래 방향으로만 짧게 언급되며 구체적 공식은 없음	flow matching 이 유일한 생성 경로; 그 공식 (직선 경로, velocity 목표, x_0 /균등 재가중) 은 논문이 아니라 flow-matching/rectified-flow 문헌 (Lipman et al.; Liu, Gong & Liu) 에서 직접 채택
prior network 내부 구조	coarse latent 위에서 자체적으로 또 한번 4-scale 까지의 멀티스케일 U-Net 을 돌림 (단 일스케일은 복잡한 과제에서 실패했다고 보고)	LatentFlowPrior 는 coarsest 레벨 하나에서 flat 하게 (추가 pooling 없이) 블록만 반복 — 더 단순하고 저비용, 단 논문의 “단 일스케일 실패” ablation 과 아직 직접 대조되지 않음
시간/조건 주입 방식	매 메시징 패시레이어에 시간·조건 임베딩을 덧셈으로 주입 ($v_i \leftarrow v_i + \text{Linear}(r_{\text{emb}})$)	AdaLN-Zero (Peebles & Xie) 로 scale/shift/gate 변조 + 항등 초기화 — 논문에 없는, 이 구현이 별도로 채택한 조건화

Table 3: LDGN 원본과 cHI-MGNflow v2 의 구조적 차이

정리하면, 본 구현이 LDGN 에서 가져온 것은 “먼저 압축하고, 그 압축된 latent 위에서만 prior 를 명시적으로 학습시킨다” 는 2 단계 설계 원칙과, 그 원칙을 정당화하는 **VGAE-collapse ablation** 자체다. 그 원칙을 실현하는 구체적인 부품들 (멀티스케일 백본, 인코더 내부 구조, 생성 모델의 수학적 형태, prior 의 내부 구조, 조건 주입 방식) 은 대부분 이리포지토리 자체의 기존 구성 요소 (HI-MGN V-cycle) 이거나 별도 문헌 (flow matching, AdaLN-Zero) 에서 가져와 독자적으로 재구성한 것이다.

6 평가 프로토콜과 현재 검증 상태

이 아키텍처가 이미 계산하는 지표는 다음과 같다 (training_profiles/training_loop.py):

- **recon** — stage 1 의 held-out reconstruction MSE.
- **det** — 3.5 절의 1-forward 결정론적 readout 의 MSE.
- **crps** — 샘플링 분포에 대한 proper score(CRPS), 앙상블 평가와 직접 대응.

- **spread/gt** — 앙상블표준편차와실제 (참) 분포표준편차의비율 — 이값이 0 에가까우면모델이노이즈채널을무시하고있다는뜻이다.

현재까지실제로확인된것은 CPU 정합성스모크테스트와이방법자체의단위테스트스위트통과, 그리고런처설정-계약검증 (preflight) 의정합성뿐이다. 이아키텍처로 **GPU** 규모의실제학습은아직수행되지않았다. 따라서본리포트는정량적결과표를포함하지않는다 — 이전아키텍처 (v1) 에서측정된수치는압축이없는다른구조에서나온것이라본아키텍처로이전되지않으며, 실측은실제 GPU 학습이수행된뒤별도리포트에서다룬다.

7 코드베이스내위치

구현은 `methods/HI_MGNFlow/`에있다. 설정키, CLI 실행법, 학습로그포맷, 그리고 (6 절보다더세부적인) 현재검증현황등운영관점의문서는 `methods/HI_MGNFlow/README.md` 가말는다. 본리포트는그아키텍처가왜이런모양이고무엇을하는지에만집중한다.

참고문헌

- Pfaff, T., Fortunato, M., Sanchez-Gonzalez, A., Battaglia, P. W. “Learning Mesh-Based Simulation with Graph Networks.” ICLR, 2021.
- Lino, M., Pfaff, T., Thuerey, N. “Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks.” ICLR, 2025. arXiv:2504.02843.
- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M., Le, M. “Flow Matching for Generative Modeling.” ICLR, 2023.
- Liu, X., Gong, C., Liu, Q. “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow.” ICLR, 2023.
- Peebles, W., Xie, S. “Scalable Diffusion Models with Transformers.” ICCV, 2023. (AdaLN-Zero)
- Kipf, T. N., Welling, M. “Variational Graph Auto-Encoders.” NeurIPS Bayesian Deep Learning Workshop, 2016. (4 절에서언급한 ablation 의 baseline)